

Razonamiento Artificial

Lógica proposicional

Conceptos Preliminares

Una **proposición** es una **afirmación** que puede ser **cierta** o **falsa**. Las **proposiciones** se combinan para formar oraciones mediante los siguientes **conectivos lógicos**:
y, o, si entonces .

Se pueden combinar oraciones en razonamientos.

Sintaxis de fórmulas (forma sintáctica de una fórmula)

p es una **variable proposicional** arbitraria.

$p \in P$ es un **conjunto** P de variables "**proposicionales**" arbitrarias.

$\in$ es **pertenece a**

Una **fórmula** puede ser uno de estos dos **símbolos especiales**:

es $\top$	" cima " es una objeto sintáctico
o $\perp$	" fondo " es una objeto sintáctico
o p	variable proposicional
o $(\neg \text{fórmula})$	negación ("no")
o $(\text{fórmula} \wedge \text{fórmula})$	conjunción ("y")
o $(\text{fórmula} \vee \text{fórmula})$	disyunción ("o")
o $(\text{fórmula} \rightarrow \text{fórmula})$	implicación ("si... entonces...")

Ejemplo para $P = \{ a, b, c \}$

Vamos a usar α (**alpha**) para referirnos a **fórmulas**:

$\alpha = (a \wedge (b \vee (\neg c)))$ alfa es una **fórmula**

Semántica: modelo y satisfacción

"**Modelo**" M respecto a P ("**situación**" o "**escenario**")

Un **conjunto** de variables posicionales es un **Modelo**, cuando los valores de las variables proposicionales se les asigna cierto o falso.

Modelo M respecto a $P :=$

1. Asignación de valores (**cierto** o **falso**) a todas las variables en P

2. $M \subseteq P$ (M es el **conjunto** de variables proposicionales con valor cierto)

$\subseteq$ es **subconjunto** ("**inclusión**")

Ejemplo para el conjunto de variables proposicionales $P = \{a, b, c\}$

Dado un **conjunto** P de **variables**, se **asigna** un **valor** de verdad **cierto** o **falso** *a cada una de esas variables proposicionales en P .*

1. $P = \{a = \text{cierto}, b = \text{falso}, c = \text{cierto}\}$
2. $\{a, c\}$

Se pueden **agrupar en un conjunto** todas las variables que tienen como valor cierto. Es decir, **las variables de P que no aparecen en ese conjunto tienen como valor falso**. Por lo que, alternativamente podemos decir que un **modelo** es un **subconjunto de P** .

El segundo componente de la semántica es la noción de "**satisfacción**".

La **satisfacción** relaciona modelos y fórmulas y **nos dice cuándo una fórmula es cierta en un modelo**.

Satisfacción"

$M \models \alpha$ (" **M hace cierto a α** ")

Este **torniquete** se puede leer como: "**hace cierto a**". El **modelo** conjunto de variables proposicionales en cierto **hace cierto** a la **fórmula** α .

α y β van a representar **fórmulas** arbitrarias y p una **variable proposicional** arbitraria.

$M \models \top$

Todo modelo hace cierta a la fórmula "cima",

es decir, el **valor de verdad** de "cima" es cierto, independientemente del modelo.

$M \not\models \perp$

Ningún modelo hace "cierto" a "fondo". Corresponde semánticamente a **falso**.

$M \models p$ **sí y solo sí p vale cierto en M ($p \in M$)**

Un **modelo** M conjunto de variables proposicionales en cierto **hace cierta** a una **fórmula** p . Que consiste únicamente en **una variable proposicional**, si esa variable vale **cierto** en el **modelo**.

Si p vale falso en M , entonces, M no satisface a la fórmula p .

M **hace cierta a p sí y solo sí p está en M .**

$M \models (\neg \alpha)$ **sí y solo sí $M \not\models \alpha$**

Un modelo **hace cierta a** la negación de α , sí solo sí ese modelo **hace falsa** a α .

$M \models (\alpha \wedge \beta)$ **sí y solo sí $M \models \alpha$ y $M \models \beta$**

Un modelo **hace cierta** a una **conjunción**, alfa y beta, sí y solo sí **hace ciertas tanto** a alfa como a beta.

$$M \models (\alpha \wedge \beta) \text{ sí y solo sí } M \models \alpha \text{ o } M \models \beta$$

Un modelo hace cierta a una **disyunción**, alfa o beta, sí y solo sí ese modelo **hace ciertas ya sea** a alfa o a beta, o a **ambas**.

$$M \models (\alpha \vee \beta) \text{ sí y solo sí } M \models \alpha, M \models \beta$$

La **implicación** cierta en un modelo si siempre que ese modelo **hace cierto** el lado izquierdo, también **hace cierto** al lado derecho.

Ejemplos:

$$\{a, b\} \models (a \wedge b)$$

El **modelo** en el que tanto **a** como **b** valen cierto, **hace cierta** a la fórmula **a y b**.

$$\{a\} \not\models (a \wedge b)$$

El **modelo** en el que **a** vale cierto y **b** vale falso, **no hace** cierta a la conjunción o fórmula **a y b**.

$$\emptyset \not\models (a \wedge b)$$

Tampoco el **modelo** en el que tanto **a** como **b** valen falso, **no hace** cierta a la conjunción.

Semántica, consecuencia lógica, equivalencia lógica y literal

La **consecuencia lógica** o **hace cierto a** ($\models$) se refiere a cuando una fórmula sigue lógicamente de otras.

Vamos a agrupar a todos los modelos **que hacen** cierta una **fórmula** en un **conjunto** que vamos a describir así:

$$M_{\text{cierto}}(\alpha) := \text{conjunto de modelos } M \text{ que hacen cierta a una fórmula } \alpha.$$

Para **consecuencia lógica** **se usa el mismo símbolo que para satisfacción**, pero ahora el lado izquierdo es un **conjunto** de fórmulas y omitimos las llaves de conjunto:

$$\alpha_1, \alpha_2, \dots, \alpha_n \models \beta$$

sí y solo sí un **conjunto** de alfa 1, alfa 2, hasta alfa n, lógicamente **implican** a una **fórmula** beta.

Si el **conjunto** de todos los **modelos** **que hacen** ciertas a todas las **fórmulas** del lado **izquierdo** están contenido en el **conjunto** de **modelos** **que hacen** cierto al lado **derecho**.

$$M_{\text{cierto}}(\alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_n) \subseteq M_{\text{cierto}}(\beta)$$

El **lado derecho**, entonces **debe preservar la verdad del lado izquierdo**, aunque es posible que el lado derecho sea verdadero es más situaciones que el lado izquierdo.

Caso particular: $\models \beta$ (β es una "tautología")

Si todo **modelo** **hace cierto** al lado **izquierdo**, o sea que el lado izquierdo es el **conjunto vacío**, **entonces** todo **modelo** también **debe hacer** cierto al lado **derecho** y decimos que el lado derecho es una **tautología**.

Ejemplo:

$((a \wedge b) \rightarrow c), a \models (b \rightarrow c)$

Del lado **izquierdo** del torniquete hay **dos fórmulas**. **a y b implican a c y a** .

$M_{\text{cierto}}((a \wedge b) \rightarrow c) \wedge a \subseteq M_{\text{cierto}}(b \rightarrow c)$ i.e. **preserva la verdad**

a	b	c	$((a \wedge b) \rightarrow c) \wedge a$	$(b \rightarrow c)$
falso	falso	falso	falso	cierto
falso	falso	cierto	falso	cierto
falso	cierto	falso	falso	falso
falso	cierto	cierto	falso	cierto
cierto	falso	falso	cierto	cierto
cierto	falso	cierto	cierto	cierto
cierto	cierto	falso	falso	falso
cierto	cierto	cierto	cierto	cierto

En el lado **izquierdo** de esta **tabla** están **todos** los **modelos** para las variables **a , b y c** . Uno en cada reglón. Podemos ver que **todos los modelos que hacen cierta a la conjunción de estas dos fórmulas hacen también cierto al lado derecho**. En este caso tiene más **modelos** que lo hacen **cierto**.

Este ejemplo representa el **razonamiento**:

ejemplo 1

a: el Sr. A iba en el tren.

b: el Sr. A tiene un arma.

c: el Sr. A cometió el homicidio.

Si el Sr. A iba en el tren **y** el Sr. A tiene un arma, **entonces** el Sr. A cometió el homicidio.

$((a \wedge b) \rightarrow c)$

Por lo tanto: **Si** el Sr. A tiene un arma, **entonces** el Sr. A cometió el homicidio. **Es correcta con respecto a la semántica que dimos**.

$(b \rightarrow c)$

Equivalencia lógica

La **equivalencia lógica** ($\equiv$).

Dos fórmulas son lógicamente equivalentes.

$\alpha \equiv \beta$ **sí y solo si** $\alpha \models \beta$ y $\beta \models \alpha$

$\equiv$ si tienen exactamente los mismos **modelos** que las hacen ciertas.

Este es un ejemplo en el que “beta” es **lógicamente equivalente** a la **fórmula** que teníamos antes.

$$\alpha \equiv ((a \wedge b) \rightarrow c) \wedge a \equiv (a \wedge (\neg b)) \vee (a \wedge b \wedge c) \equiv \beta$$

La **equivalencia lógica** nos hace darnos cuenta de que **algunos conectivos lógicos se pueden expresar en términos de otros**. Por ejemplo, la **disyunción** se puede expresar en términos de **negación** y **conjunción**.

$$\alpha \vee \beta \equiv \neg(\neg \alpha \wedge \neg \beta)$$

Similarmente con la **implicación** en términos con **negación** y **disyunción**.

$$\alpha \rightarrow \beta \equiv \neg \alpha \vee \beta$$

Literal

Una **literal** es una **variable proposicional** (afirmada) o su **negación** (negada). La vamos a representar con la letra ℓ literal := variable o negación de variable

ℓ es p o $\neg p$ donde $p \in P$

Una **fórmula** en **Forma Normal Disyuntiva** (FND) es una **disyunción** de **conjunciones** de **literales**. Es decir,

$$(\ell_{1,1} \wedge \dots \wedge \ell_{1,n_1}) \vee (\ell_{2,1} \wedge \dots \wedge \ell_{2,n_2}) \vee \dots \vee (\ell_{m,1} \wedge \dots \wedge \ell_{m,n_m})$$

Cada **conjunción de literales** se llama **término**.

Esta forma **FND** se llama Normal porque **toda fórmula arbitraria** es lógicamente **equivalente a una fórmula en forma normal disyuntiva**.

Forma Normal Conjuntiva

La **Forma Normal Conjuntiva** (FNC) tiene una **conjunción** de **disyunciones literales**. Y a cada **disyunción de literales** se llama **cláusula**.

$$(\ell_{1,1} \vee \dots \vee \ell_{1,n_1}) \wedge (\ell_{2,1} \vee \dots \vee \ell_{2,n_2}) \wedge \dots \wedge (\ell_{m,1} \vee \dots \vee \ell_{m,n_m})$$

Cláusula

Una **cláusula** es una **disyunción** de **literales**.

Una **fórmula** es **satisfactible** si existe un **modelo** que la hace cierta. Pueden existir más modelos que la hagan cierta.

α es satisfactible si existe (al menos) un M tal que $M \models \alpha$

Una **fórmula** es **tautología** si todo modelo la hace cierta.

α es tautología o fórmula válida si $\models \alpha$ (i.e., para todo M , $M \models \alpha$)

Estos dos conceptos están relacionados. Es posible demostrar que una fórmula arbitraria “alfa” es **satisfactible**,

α es satisfactible sí y solo sí $\neg\alpha$ no es tautología.

Inferencia

La **inferencia** ($\vdash$) se refiere a cómo podemos razonar con respecto a la semántica que damos. Una **regla de inferencia** dice qué podemos **deducir** a partir de qué en un solo paso. La idea para poder **deducir una fórmula** a partir de otras en varios pasos es aplicar sucesivamente **reglas de inferencia**. Hay **dos partes** en una **regla de inferencia**,

$((a \wedge b) \rightarrow c) \quad a$

$b \rightarrow c$

dadas las **fórmulas** de arriba de la línea, **deducimos** la **fórmula** de abajo de la línea.
Deducción natural.

$\alpha \wedge \beta$

----- eliminación de $\wedge$

α

$\alpha \quad \beta$

----- introducción de $\wedge$

$\alpha \wedge \beta$

A partir de α y β se puede **deducir** $\alpha \wedge \beta$. También a partir de dos fórmulas α y β , podemos **deducir** la **fórmula** $\alpha \wedge \beta$.

Una regla importante en latín *modus ponens* o eliminación de la **implicación**.

$\alpha \quad \alpha \rightarrow \beta$

β

Hay otras **reglas** para **introducir** la **implicación**, reglas para **eliminar** e **introducir** la **disyunción** y la **negación**.

$\vdash$ se lee como **inferen**. Afirma que a partir de la **conjunción** de las **fórmulas** del lado izquierdo podemos **inferir** el lado derecho aplicando **reglas de inferencia**.

$\alpha_1, \alpha_2, \dots, \alpha_n \vdash \beta$

si existen aplicaciones de reglas de inferencia que permiten convertir $\alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_n$ en β

Un **sistema de inferencia** es un **conjunto de reglas de inferencia**. No forzosamente las reglas de la deducción natural. Un **sistema de inferencia** es **correcto** si todo lo que podemos **inferir** con ese sistema es **consecuencia lógica**:

si $\alpha_1, \alpha_2, \dots, \alpha_n \vdash \beta$, **entonces** $\alpha_1, \alpha_2, \dots, \alpha_n \models \beta$

o del mismo modo un **sistema de inferencia** es **completo** si nos permite **inferir** todo lo que es la **consecuencia lógica**:

si $\alpha_1, \alpha_2, \dots, \alpha_n \models \beta$, **entonces** $\alpha_1, \alpha_2, \dots, \alpha_n \vdash \beta$

El **problema SAT** es un problema importante para saber si una **fórmula** es **satisfactible** o no. Es decir, si existen o no modelos que la hagan cierta.

dada α , ¿es α satisfactible?

1. α en forma normal **disyuntiva**: FND-SAT

$(\ell_{1,1} \wedge \dots \wedge \ell_{1,n1}) \vee (\ell_{2,1} \wedge \dots \wedge \ell_{2,n2}) \vee \dots \vee (\ell_{m,1} \wedge \dots \wedge \ell_{m,nm})$

1. α en forma normal **conjuntiva**: FNC-SAT

$(\ell_{1,1} \vee \dots \vee \ell_{1,n1}) \wedge (\ell_{2,1} \vee \dots \vee \ell_{2,n2}) \wedge \dots \wedge (\ell_{m,1} \vee \dots \vee \ell_{m,nm})$

Aquí tenemos que encontrar una **asignación de variables** que haga **ciertas** a todas las **cláusulas** simultáneamente.

Satisfactibilidad para las **fórmulas** en forma normal **conjuntiva**.

Problema 1. SAT (FNC-SAT)

dada α en FNC, ¿existe M tal que $M \models \alpha$?

Problema 2. **verificación de modelos**

dada α y M , ¿ $M \models \alpha$?

Formalmente, se toma un **tiempo polinomial** en la **longitud** de la **fórmula**. Todos los algoritmos que se conocen para **SAT** toman un **tiempo exponencial** en la **longitud** de la **fórmula** en el peor de los casos, que es más ineficiente que los algoritmos de **tiempo polinomial**.

SAT pertenece a una clase importante de problemas llamada **NP-completos**.

Problemas NP-completos

¿Es más fácil **verificación de modelos** que SAT?

SAT es **NP-completo** (al igual que muchos otros problemas)

(todos los algoritmos conocidos toman un **tiempo exponencial**)

muchos de los problemas importantes son **NP-completos**

problemas **NP-completos** se atacan con búsqueda (**inteligencia artificial**)

Hay problemas que podemos resolver de manera directa, sin tener que hacer búsqueda, por ejemplo el problema de ordenamiento de una sucesión de números. Sin embargo, para resolver un **problema NP-completo** debemos en general hacer búsqueda y es en problemas como estos en los que se concentra la **inteligencia artificial**.

Algoritmo DPLL

En honor a sus investigadores Davis, Putnam, Logemann y Loveland (DPLL), el algoritmo **DPLL** resuelve el problema de la **satisfactibilidad booleana**.

El algoritmo **DPLL** es un **algoritmo de descenso recursivo** el cual **descompone el problema complejo en subproblemas más simples**, para ayudar a determinar la **satisfactibilidad** de una **expresión booleana**.

La estrategia de los **algoritmos de búsqueda con retroceso** es comenzar por asignar una solución **parcial**. De manera sistemática e incremental, se busca una solución **completa**. Si en algún momento del algoritmo se **determina** que no va a conducir a una **solución completa**, entonces retrocede y asigna otra **solución parcial**. Estos pasos se repiten hasta determinar la solución completa o que no exista solución al problema.

Simplificar

El objetivo del algoritmo DPLL es **simplificar** la fórmula hasta **determinar el valor cierto**, es decir que la fórmula sea **satisfacible**.

En este ejemplo:

Tenemos la **cláusula** A disyunción u o B

$(A \vee B)$

para **simplificarla** asumimos que alguna de las variables toma un **valor de verdad particular**.

Por ejemplo:

Si A es **cierta**, concluimos inmediatamente que la **fórmula** es **satisfacible**.

Si A es **falsa**, entonces la **fórmula** se **simplifica** a la **cláusula** B . Esta puede **simplificarse** a su vez asumiendo algún valor para B .

Si B es **cierto**, entonces concluimos **cierto**.

Si B es **falso**, entonces es **falso**.

En el caso de encontrar alguna **fórmula falsa**, el **algoritmo** debe continuar buscando. Para determinar **satisfactibilidad** es necesario encontrar un valor **cierto**.

Vamos a definir la **simplificación** de una **cláusula** en forma normal **conjuntiva** (FNC) con una **literal**.

$$(\ell_{1,1} \vee \dots \vee \ell_{1,n1}) \wedge (\ell_{2,1} \vee \dots \vee \ell_{2,n2}) \wedge \dots \wedge (\ell_{m,1} \vee \dots \vee \ell_{m,nm})$$

Si asignamos a la variable v el valor de verdad **cierto**, entonces formamos una **literal**

$$\ell = v$$

Si asignamos el valor de **falso**, se forma la **literal complementaria**

$$\ell = \neg v$$

Toda **cláusula** que contenga la **literal** ℓ , se elimina de la **fórmula simplificada**, porque es **cierta**. Si una **cláusula** contiene la **literal complementaria** ℓ' borramos ℓ' de la **cláusula** porque es **falsa**.

Imaginemos que tenemos la **fórmula** con el **conjunto de cláusulas** y esta **literal** aparece en alguna de ellas. En esta **cláusula**, como está en forma afirmada, vamos a **eliminar la cláusula completamente al simplificarla**, porque esta se vuelve verdadera y está en conjunción con las otras **cláusulas**.

Si la **literal** aparece en su forma **complementaria** o su forma **negada**, entonces **eliminamos la literal**, porque esta se vuelve **falsa** y está en disyunción con las otras **literales**.

Por ejemplo:

La **fórmula** ϕ tiene **dos cláusulas**. Vamos a simplificar la fórmula con la literal **B**. La primera **cláusula** se elimina porque la literal **B** aparece con el mismo signo. La segunda **cláusula** tiene la **literal complementaria**, entonces borramos dicha literal. El resultado es una fórmula con una sola cláusula.

Si la fórmula $\phi = (A \vee B \vee \neg C) \wedge (\neg A \vee \neg B)$,
entonces $\phi(B) = (\neg A)$

Los **casos base** del **algoritmo DPLL** son aquellos que se pueden resolver de manera trivial. Hay **dos** casos:

1. Cuando la **fórmula** se vuelve **falsa**. Esto es a través de que las cláusulas o alguna de ellas, se volvieron falsa. Es decir, **no tienen literales**.
2. Cuando **ya no hay cláusulas**, porque todas ellas se volvieron **verdaderas** y se **eliminaron de la fórmula**.

Cláusula unitaria

Otro concepto importante para el algoritmo es el de **cláusula unitaria**. Una **cláusula unitaria** es aquella que contiene solo una **literal**. Se simplifica la fórmula asumiendo que la **literal** de una **cláusula unitaria** es **cierta**.

Literal pura

Y también es importante el concepto de **literal pura**. Una **literal pura** es aquella que aparece con el mismo signo en todas las **cláusulas**.

Por ejemplo, en la fórmula siguiente **A** es pura, pero tanto **B** como **C** no lo son:

$(A \vee B \vee C) \wedge (A \vee \neg B \vee \neg C) \wedge (\neg C)$

Si la **fórmula** original es **satisfactible**, al **simplificarla** con la **literal pura**, entonces la **fórmula** resultante también es **satisfactible**.

A continuación vamos a ver el **algoritmo DPLL**.

La **entrada** del **algoritmo DPLL** es la **fórmula** en forma normal conjuntiva (FNC) y la **salida** es **verdadera** cuando fórmula es **satisfactible** y **falso** cuando no lo es.

Entrada: ϕ : Cadena con la **fórmula FNC**.

Salida: **cierto** si la **fórmula** es **satisfactible**, **falso** en otra forma.

1. Si la expresión de la **fórmula** ϕ es **vacía** significa que todas las **cláusulas** se lograron, es decir que la **fórmula** es **satisfactible** y regresa **cierto**.
2. Si existe una **cláusula** vacía en ϕ regresa **falso**. La **cláusula** no se puede lograr o no se puede hacer verdadera.
3. Si ℓ es una **cláusula unitaria** en ϕ regresa **DPLL($\phi(\ell)$)**. Tenemos una cláusula unitaria. Si existe una **cláusula unitaria**, entonces **simplificamos** con la **literal** que aparece en esa **cláusula unitaria** e invocamos el **algoritmo** de manera **recursiva**.
4. Si existe una **literal pura** ℓ en ϕ regresa **DPLL($\phi(\ell)$)**. Tenemos una **literal pura**, entonces asumimos esa **literal** **simplificando la cláusula original**.
5. Selecciona una variable v que aparece en ϕ . Seleccionamos una variable de manera arbitraria.
6. Si **DPLL($\phi(\ell)$)** regresa **cierto**. **Simplificamos** la **fórmula** con la **literal** donde la variable seleccionada está afirmada e invocamos de manera **recursiva** el **algoritmo DPLL**. Si el **algoritmo** nos regresa **cierto**, concluimos **satisfactibilidad**. Si regresa algo entonces vamos al paso siete.
7. En caso contrario regresa **DPLL($\phi(\neg v)$)**. Vamos a probar con la **literal complementaria**. **Simplificamos** la **fórmula** e invocamos de manera **recursiva** el **algoritmo DPLL**. El resultado de esta invocación es lo que regresará el algoritmo.

Los primeros dos pasos, se refieren a los casos base.

Para ejemplificar la aplicación del **algoritmo DPLL**. Vamos a definir variables booleanas para la **víctima**, el **detective** y **dos sospechosos** del **homicidio**:

DA = Detective en vagón A

S1A = Sospechoso 1 en vagón A

CS1 = Cuchillo Sospechoso 1

SS1 = Sangre en pañuelo de Sospechoso 1

S2A = Sopechoso 2 en vagón A

CS2 = Cuchillo Sospechoso 2

SS2 = Sangre en pañuelo de Sospechoso 2

VA = Víctima en vagón A

S1MV = Sospechoso 1 mata la víctima

S2MV = Sospechoso 2 mata la víctima

Sabemos que alguno de los sospechoso mató a la víctima. Esto lo representamos con la disyunción de **SM1V** y **SM2V**. El sospechoso 1 mató a la víctima o el sospechoso 2 mató a la víctima:

$$(SM1V \vee SM2V)$$

Sabemos que **si** el sospechoso 1 mató a la víctima, **entonces** tiene un cuchillo y sangre en su pañuelo, además de que tanto el **sospechoso** y la **víctima están** en el mismo vagón pero en **otro distinto** vagón al **detective**:

$$SM1V \rightarrow (CS1 \wedge SS1) \wedge ((S1A \wedge VA \wedge \neg DA) \vee (\neg S1A \wedge \neg VA \wedge DA))$$

Sabemos lo mismo para el sospechoso 2:

$$SM2V \rightarrow (CS2 \wedge SS2) \wedge ((S2A \wedge VA \wedge \neg DA) \vee (\neg S2A \wedge \neg VA \wedge DA))$$

Sabemos que no todos estuvieron el mismo vagón A o alguien no estaba en el vagón A:

$$(\neg S1A \vee \neg S2A \vee \neg VA \vee DA)$$

Para aplicar **DPLL** transformamos las fórmulas en forma normal conjuntiva.

$$(\ell_{1,1} \vee \dots \vee \ell_{1,n1}) \wedge (\ell_{2,1} \vee \dots \vee \ell_{2,n2}) \wedge \dots \wedge (\ell_{m,1} \vee \dots \vee \ell_{m,nm})$$

$$SM1V \rightarrow (CS1 \wedge SS1) \wedge ((S1A \wedge VA \wedge \neg DA) \vee (\neg S1A \wedge \neg VA \wedge DA))$$

Expresamos la **implicación** ($\rightarrow$) en términos o forma equivalente mediante la **negación** y **disyunción**: $\alpha \rightarrow \beta \equiv \neg \alpha \vee \beta$

$$\neg SM1V \vee ((CS1 \wedge SS1) \wedge ((S1A \wedge VA \wedge \neg DA) \vee (\neg S1A \wedge \neg VA \wedge DA)))$$

En la fórmula que representa la consecuencia de la implicación, distribuimos para que nos quede la disyunción de literales.

$$\neg SM1V \vee (CS1 \wedge SS1 \wedge (S1A \vee \neg S1A) \wedge (S1A \vee \neg VA) \wedge (S1A \vee DA) \wedge (VA \vee \neg S1A) \wedge (VA \vee \neg VA) \wedge (VA \vee DA) \wedge (\neg DA \vee \neg S1A) \wedge (\neg DA \vee \neg VA) \wedge (\neg DA \vee DA))$$

Se eliminan las complementarias:

$$\neg SM1V \vee (CS1 \wedge SS1 \wedge (S1A \vee \neg S1A) \wedge (S1A \vee \neg VA) \wedge (S1A \vee DA) \wedge (VA \vee \neg S1A) \wedge (VA \vee \neg VA) \wedge (VA \vee DA) \wedge (\neg DA \vee \neg S1A) \wedge (\neg DA \vee \neg VA) \wedge (\neg DA \vee DA))$$

y a todas las que sobran se les agrega la disyunción de $\neg SM1V$ al final:

$$\neg SM1V \vee ($$

$$CS1 \wedge$$

$$SS1 \wedge$$

$$(S1A \vee \neg VA) \wedge (S1A \vee DA) \wedge$$

$$(VA \vee \neg S1A) \wedge (VA \vee DA) \wedge$$

$$(\neg DA \vee \neg S1A) \wedge (\neg DA \vee \neg VA)$$

$$)$$

Distribuimos nuevamente, logrando la forma deseada.

$$(\ell_{1,1} \vee \dots \vee \ell_{1,n1}) \wedge (\ell_{2,1} \vee \dots \vee \ell_{2,n2}) \wedge \dots \wedge (\ell_{m,1} \vee \dots \vee \ell_{m,nm})$$

$$(CS1 \vee \neg SM1V) \wedge$$

$$(SS1 \vee \neg SM1V) \wedge$$

$$(S1A \vee \neg VA \vee \neg S1MV) \wedge$$

$$(S1A \vee DA \vee \neg S1MV) \wedge$$

$$(VA \vee \neg S1A \vee \neg S1MV) \wedge$$

$$(VA \vee DA \vee \neg S1MV) \wedge$$

$$(\neg DA \vee \neg S1A \vee \neg S1MV) \wedge$$

$$(\neg DA \vee \neg VA \vee \neg S1MV)$$

Aquí ponemos en conjunción **FNC** todas las **fórmulas** resultando una fórmula con **18 cláusulas**:

$$(S1MV \vee S2MV) \wedge$$

$$//$$

$$(CS1 \vee \neg S1MV) \wedge$$

$$(SS1 \vee \neg S1MV) \wedge$$

$$(S1A \vee \neg VA \vee \neg S1MV) \wedge$$

$$(S1A \vee DA \vee \neg S1MV) \wedge$$

$$(VA \vee \neg S1A \vee \neg S1MV) \wedge$$

$$(VA \vee DA \vee \neg S1MV) \wedge$$

$$(\neg DA \vee \neg S1A \vee \neg S1MV) \wedge$$

$$(\neg DA \vee \neg VA \vee \neg S1MV) \wedge$$

$$//$$

$$(CS2 \vee \neg S2MV) \wedge$$

$$(SS2 \vee \neg S2MV) \wedge$$

$$(S2A \vee \neg VA \vee \neg S2MV) \wedge$$

$$(S2A \vee DA \vee \neg S2MV) \wedge$$

$$(VA \vee \neg S2A \vee \neg S2MV) \wedge$$

$$(VA \vee DA \vee \neg S2MV) \wedge$$

$$(\neg DA \vee \neg S1A \vee \neg S2MV) \wedge$$

$$(\neg DA \vee \neg VA \vee \neg S2MV) \wedge$$

$$//$$

$$(\neg S1A \vee \neg S2A \vee \neg VA \vee \neg DA)$$

Vemos que la fórmula no es vacía, no hay cláusulas sin literales, no hay cláusulas unitarias, pero existe una literal pura **SS1** que aparece con el mismo signo en todas las cláusulas. $\phi(SS1)$

$$\begin{aligned}\phi = & (VA \vee \neg S1A \vee \neg S1MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg S1A \vee \neg S1MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2A \vee \neg VA) \wedge (CS1 \vee \neg S1MV) \wedge (SS1 \vee \neg S1MV) \wedge \\ & (CS2 \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2MV) \wedge (S1MV \vee S2MV) \wedge (S1A \vee \neg S1MV \vee DA) \wedge \\ & (S1A \vee \neg VA \vee \neg S1MV) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge (SS2 \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge \\ & (DA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2MV)\end{aligned}$$

DPLL simplifica la fórmula, regresará el resultado de la invocación recursiva con la fórmula simplificada. **DPLL**, operando la fórmula simplificada determina que existe la literal pura **CS1**. Simplificación $\phi(CS1)$

$$\begin{aligned}\phi = & (VA \vee \neg S1A \vee \neg S1MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg S1A \vee \neg S1MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2A \vee \neg VA) \wedge (CS1 \vee \neg S1MV) \wedge (SS1 \vee \neg S1MV) \wedge \\ & (CS2 \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2MV) \wedge (S1MV \vee S2MV) \wedge (S1A \vee \neg S1MV \vee DA) \wedge \\ & (S1A \vee \neg VA \vee \neg S1MV) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge (SS2 \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge \\ & (DA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2MV)\end{aligned}$$

Simplifica la fórmula, regresará el resultado de la invocación con la fórmula simplificada.

$$\begin{aligned}\phi = & (VA \vee \neg S1A \vee \neg S1MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg S1A \vee \neg S1MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2A \vee \neg VA) \wedge (CS1 \vee \neg S1MV) \wedge (SS1 \vee \neg S1MV) \wedge \\ & (CS2 \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2MV) \wedge (S1MV \vee S2MV) \wedge (S1A \vee \neg S1MV \vee DA) \wedge \\ & (S1A \vee \neg VA \vee \neg S1MV) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge (SS2 \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge \\ & (DA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2MV)\end{aligned}$$

$$\begin{aligned}\phi = & (VA \vee \neg S1A \vee \neg S1MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg S1A \vee \neg S1MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2A \vee \neg VA) \wedge (CS2 \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2MV) \wedge \\ & (S2MV \vee S1MV) \wedge (S1A \vee \neg S1MV \vee DA) \wedge (S1A \vee \neg VA \vee \neg S1MV) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge \\ & (SS2 \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (DA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (\neg DA \\ & \vee \neg VA \vee \neg S2MV)\end{aligned}$$

Literal pura **SS2**:

$$\begin{aligned}\phi = & (VA \vee \neg S1A \vee \neg S1MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg S1A \vee \neg S1MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2A \vee \neg VA) \wedge (CS2 \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2MV) \wedge \\ & (S2MV \vee S1MV) \wedge (S1A \vee \neg S1MV \vee DA) \wedge (S1A \vee \neg VA \vee \neg S1MV) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge \\ & (SS2 \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (DA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (\neg DA \\ & \vee \neg VA \vee \neg S2MV)\end{aligned}$$

Simplificación:

$$\begin{aligned}\phi = & (VA \vee \neg S1A \vee \neg S1MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg S1A \vee \neg S1MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2A \vee \neg VA) \wedge (CS2 \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2MV) \wedge \\ & (S2MV \vee S1MV) \wedge (S1A \vee \neg S1MV \vee DA) \wedge (S1A \vee \neg VA \vee \neg S1MV) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge \\ & (SS2 \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (DA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (\neg DA \\ & \vee \neg VA \vee \neg S2MV)\end{aligned}$$

$$\begin{aligned}\phi = & (VA \vee \neg S1A \vee \neg S1MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg S1A \vee \neg S1MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2A \vee \neg VA) \wedge (CS2 \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2MV) \\ & \wedge (S2MV \vee S1MV) \wedge (S1A \vee \neg S1MV \vee DA) \wedge (S1A \vee \neg VA \vee \neg S1MV) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge \\ & (\neg VA \vee S2A \vee \neg S2MV) \wedge (DA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2MV)\end{aligned}$$

Literal pura **CS2** y simplificación $\phi(CS2)$:

$$\begin{aligned}\phi = & (VA \vee \neg S1A \vee \neg S1MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg S1A \vee \neg S1MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2A \vee \neg VA) \wedge (CS2 \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2MV) \\ & \wedge (S2MV \vee S1MV) \wedge (S1A \vee \neg S1MV \vee DA) \wedge (S1A \vee \neg VA \vee \neg S1MV) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge \\ & (\neg VA \vee S2A \vee \neg S2MV) \wedge (DA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2MV)\end{aligned}$$

Elige una variable arbitraria S1A y simplificación $\phi(S1A)$:

$$\begin{aligned}\phi = & (VA \vee \neg S1A \vee \neg S1MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg S1A \vee \neg S1MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg S1A \vee \neg S2A \vee \neg VA) \wedge (\neg DA \vee \neg S1A \vee \neg S2MV) \wedge \\ & (S2MV \vee S1MV) \wedge (S1A \vee \neg S1MV \vee DA) \wedge (S1A \vee \neg VA \vee \neg S1MV) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge \\ & (\neg VA \vee S2A \vee \neg S2MV) \wedge (DA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2MV)\end{aligned}$$

--

Este es un punto de posible bifurcación. El algoritmo regresará este punto en caso de que la simplificación nos conduzca a cierto.

$$\begin{aligned}\phi = & (\neg DA \vee \neg S1MV) \wedge (S2MV \vee S1MV) \wedge (DA \vee S2A \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2A) \wedge (\neg DA \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge \\ & (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV)\end{aligned}$$

Elige una variable arbitraria DA y simplificación $\phi(DA)$:

$$\begin{aligned}\phi = & (\neg DA \vee \neg S1MV) \wedge (S2MV \vee S1MV) \wedge (DA \vee S2A \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2MV) \wedge \\ & (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2A) \wedge (\neg DA \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge \\ & (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV)\end{aligned}$$

Elige una variable arbitraria DA y simplificación $\phi(DA)$:

$$\begin{aligned}\phi = & (\neg S1MV) \wedge (\neg VA \vee \neg S2MV) \wedge (\neg VA \vee \neg S1MV) \wedge (S2MV \vee S1MV) \wedge \\ & (\neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV) \wedge (\neg VA \vee \neg S2A) \wedge (VA \vee \neg S2A \vee \neg S2MV)\end{aligned}$$

$$\begin{aligned}\phi = & (\neg S1MV) \wedge \\ & (\neg VA \vee \neg S2MV) \wedge \\ & (\neg VA \vee \neg S1MV) \wedge \\ & (S2MV \vee S1MV) \wedge \\ & (\neg S2MV) \wedge \\ & (\neg VA \vee S2A \vee \neg S2MV) \wedge \\ & - \\ & (\neg VA \vee \neg S2A) \wedge \\ & (VA \vee \neg S2A \vee \neg S2MV) \wedge\end{aligned}$$

$$(S2A \vee \neg S2MV) \wedge (VA \vee \neg S2MV) \wedge (VA \vee \neg S1MV) \wedge (VA \vee \neg S1MV)$$

Cláusula unitaria negada $\neg S1MV$ y simplificación $\phi(\neg S1MV)$:

$$\phi = (\neg S1MV) \wedge (\neg VA \vee \neg S2MV) \wedge (\neg VA \vee \neg S1MV) \wedge (S2MV \vee S1MV) \wedge (\neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV) \wedge (\neg VA \vee \neg S2A) \wedge (VA \vee \neg S2A \vee \neg S2MV)$$

$$\phi = (\neg VA \vee \neg S2MV) \wedge (S2MV) \wedge (\neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (\neg VA \vee \neg S2A) \wedge (VA \vee \neg S2A \vee \neg S2MV)$$

$$(\neg VA \vee \neg S1MV) \wedge (VA \vee \neg S1MV) \wedge$$

Cláusula unitaria negada $\neg S2MV$ y simplificación $\phi(\neg S2MV)$:

$$\phi = (\neg VA \vee \neg S2MV) \wedge (S2MV) \wedge (\neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (\neg VA \vee \neg S2A) \wedge (VA \vee \neg S2A \vee \neg S2MV)$$

$$\phi = (\neg VA \vee \neg S2A)$$

$$(\neg VA \vee \neg S2MV) \wedge (S2MV) \wedge (\neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S2A \vee \neg S2MV)$$

Caso base, cláusula sin literales:

$$\phi = () \wedge (\neg VA \vee \neg S2A)$$

El algoritmo retrocede al punto de posible bifurcación.

Asignamos la literal complementaria en este punto, negado $\neg DA$ y simplificación

$\phi(\neg DA)$:

$$\phi = (\neg DA \vee \neg S1MV) \wedge (S2MV \vee S1MV) \wedge (DA \vee S2A \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2MV) \wedge (VA \vee DA \vee \neg S2MV) \wedge (\neg DA \vee \neg VA \vee \neg S2A) \wedge (\neg DA \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV \vee DA) \wedge (\neg DA \vee \neg VA \vee \neg S1MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV)$$

$$\phi = (\neg S1MV) \wedge (S2MV \vee S1MV) \wedge (S2A \vee \neg S2MV) \wedge (\neg VA \vee \neg S2MV) \wedge (VA \vee \neg S2MV) \wedge (\neg VA \vee \neg S2A) \wedge (\neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV) \wedge (\neg VA \vee \neg S1MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV)$$

$$\phi = (S2MV \vee S1MV) \wedge (S2A \vee \neg S2MV) \wedge (VA \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV)$$

$$(\neg S1MV) \wedge (\neg S2MV) \wedge (\neg VA \vee \neg S1MV) \wedge (\neg VA \vee \neg S2MV) \wedge (\neg VA \vee \neg S2A) \wedge$$

Simplificamos literal VA.

$$\phi = (S2MV \vee S1MV) \wedge (S2A \vee \neg S2MV) \wedge (VA \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV)$$

$$\phi = (S2MV \vee S1MV) \wedge (S2A \vee \neg S2MV) \wedge (VA \vee \neg S2MV) \wedge (\neg VA \vee S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV) \wedge (VA \vee \neg S2A \vee \neg S2MV) \wedge (VA \vee \neg S1MV)$$

$$\phi = (S2MV \vee S1MV) \wedge (S2A \vee \neg S2MV) \wedge (S2A \vee \neg S2MV)$$

$$\begin{aligned} & (VA \vee \neg S2MV) \wedge \\ & (VA \vee \neg S1MV) \wedge \\ & (VA \vee \neg S1MV) \wedge \\ & (\neg VA \vee S2A \vee \neg S2MV) \wedge \\ & (VA \vee \neg S2A \vee \neg S2MV) \wedge \end{aligned}$$

Simplificamos literal pura $S1MV$. $\phi(S1MV)$

$$\phi = (S2MV \vee S1MV) \wedge (S2A \vee \neg S2MV) \wedge (S2A \vee \neg S2MV)$$

$$\phi = (S2A \vee \neg S2MV) \wedge (S2A \vee \neg S2MV)$$

Simplificamos literal pura $S2A$. $\phi(S2A)$

$$\phi = (S2A \vee \neg S2MV) \wedge (S2A \vee \neg S2MV)$$

Simplificamos caso base, fórmula sin cláusulas:

$$\phi = \text{expresión vacía}$$

LA FÓRMULA ES SATISFACTIBLE

Lógica temporal y Lógica de predicados

Lógica temporal

Conceptos preliminares y sintaxis de lógica temporal

La **lógica temporal** se puede ver como una **extensión** de la **lógica proposicional**.

En la **lógica proposicional** un **modelo** era una **asignación** de variables. En cambio, ahora un **modelo** va a consistir en **varias asignaciones de variables**. A cada **asignación** le vamos a llamar **estado**.

Dado un **estado**, solamente vamos a escribir las **variables** que tienen **valor cierto**, como con la lógica proposicional.

Además hay una **relación** entre **estados**. Un **estado** está **relacionado** con **otro estado** si es posible pasar **de uno al otro** en una unidad de **tiempo**.

Modelo temporal

modelo:

- en lógica proposicional: modelo = una sola asignación de variables
- en lógica temporal: modelo =
 - 1 varias asignaciones de variables (cada asignación = "estado") (escribimos exactamente las variables que tienen valor *cierto*)
 - 2 un estado está *relacionado* con otro si es *posible* pasar del primero al segundo en una unidad de tiempo

Si tenemos tres variables "a", "b" y "c",

Si tenemos tres variables **a**, **b** y **c** en el **estado s**, **a** y **b** valen **cierto** y **c** vale **falso**.

En el **estado t**, **b** y **c** valen **cierto** y **a** vale **falso**. Al transcurrir el **tiempo**, podemos **salir del estado s** para **volver al estado s** o **pasar al estado t**. Una vez en el **estado t**, solo podemos **regresar a él mismo**.

Sintaxis de la Lógica Temporal Lineal (LTL)

Las fórmulas son las mismas que en la lógica proposicional. Más los operadores temporales.

Una **fórmula** precedida de **X** es también una **fórmula**.

conjunto P de variables "**proposicionales**" arbitrarias; **p** $\in$ **P**

Una **fórmula** puede ser uno de estos dos **símbolos especiales**:

es $\top$	"cima" es una objeto sintáctico
o $\perp$	"fondo" es una objeto sintáctico
o p	variable proposicional
o ($\neg$ fórmula)	negación ("no")
o (fórmula $\wedge$ fórmula)	conjunción ("y")
o (fórmula $\vee$ fórmula)	disyunción ("o")
o (fórmula $\rightarrow$ fórmula)	implicación ("si... entonces...")
o (X fórmula)	"neXt" (mañana)
o (F fórmula)	"Future" (ahora en el futuro)
o (G fórmula)	"Global" (siempre)
un otros operadores	

Semántica de lógica temporal


Definimos **modelo** y **satisfacción**. Más el concepto de **trayectoria**. Después **equivalencia lógica**.

Un modelo M tiene cuatro partes:

1. Un **conjunto P** de **variables proposicionales** ($a, b, \dots$)
2. Un **conjunto S** de **estados** ($s, t, \dots$). Cada **estado** tiene que estar **etiquetado** con un **conjunto** de variables **proposicionales**.
3. Una **función L** de etiquetamiento ("Labeling"). Que va del **conjunto S** de **estados** al **conjunto potencia** de P . Dado s , $L(s) =$ **conjunto** de variables que valen cierto en s (i.e., $L:S \rightarrow 2^P$). Es decir, dado un estado o un elemento de S , regresa un conjunto de variables o un elemento del conjunto de potencia de P .
4. Una relación R que es un **conjunto** de parejas de **estados** sobre S (i.e., $R \subseteq S \times S$). Todo estado sale por lo menos una flecha de cada **estado** (i.e., para todo estado s , existe una pareja de estados con s primera componente: s' tal que si $(s, s') \in R$).

Una **trayectoria** es una **sucesión** infinita de **estados** que respeta a la **relación R** .

Aquí tenemos tres trayectorias que abandonan s :



La primera abandona s en el segundo **estado** y pasa a t .

La segunda sale de s en el tercer **estado** y pasa a t .

La tercera pasa a t en el cuarto **estado**.

Es posible que exista más de una flecha que sale de un **estado**. Cuando esto ocurre, se dice que el modelo es **no determinista**. El **no determinismo** es útil para **modelar**, por ejemplo **decisiones** tomadas **por un agente externo** al modelo.

Supongamos que:

a = denota que el homicida está fuera del compartimento de la víctima,

b = tren en movimiento

c = víctima muerta

El hecho de que **s** tenga una flecha hacia sí misma **s**, y otra hacia **t**, indica que nos vamos en qué momento el homicida va a decidir entrar al compartimento de la víctima.

Satisfacción para trayectoria.

Suponemos una trayectoria que denotamos con **pi**, que es una sucesión infinita de estados y que empieza en **s0** y fórmulas alpha y beta.

trayectoria $\pi = s_0 s_1 s_2 \dots$; fórmulas LTL α y β

$\pi \models \top$ $\pi \not\models \perp$
 $\pi \models p$ sí y solo sí $p \in L(s_0)$
 $\pi \models (\neg \alpha)$ sí y solo sí $\pi \not\models \alpha$
 $\pi \models (\alpha \wedge \beta)$ sí y solo sí $\pi \models \alpha$ y $\pi \models \beta$
 $\pi \models (X \alpha)$ sí y solo sí $\pi^1 \models \alpha$
 $\pi \models (F \alpha)$ sí y solo sí existe $i \geq 0$ tal que $\pi^i \models \alpha$
 $\pi \models (G \alpha)$ sí y solo sí para toda $i \geq 0$, $\pi^i \models \alpha$

$\pi^i \models s_i s_{i+1} s_{i+2} \dots$

Vamos a utilizar **superíndices** para denotar **sufijos** de una **trayectoria**. **Pi** con superíndice **i** indica el resto de la **trayectoria** a partir del **i-ésimo estado**, empezando en **s0**.

Pi super 1, es pi sin su primer estado, decir, pi super uno es la trayectoria que resulta de avanzar un instante de tiempo hacia el futuro.

Entonces, **X alpha** es cierto en **pi** si y solo si **alpha** es cierto en la trayectoria que **resulta de borrar** el primer **estado** de **pi**. $\pi \models (X \alpha)$ sí y solo sí $\pi^1 \models \alpha$

Pi hace cierta a **F alpha** sí y solo si existe un **sufijo de pi** que haga cierta a **alpha**. Es decir, si alpha es cierta **en algún instante** presente o futuro. $\pi \models (F \alpha)$ sí y solo si existe $i \geq 0$ tal que $\pi^i \models \alpha$

Pi hace cierta a **G alpha** sí y solo si los sufijos de pi hacen cierta a alpha. Es decir, si alpha es cierta **siempre** en la **trayectoria**. $\pi \models (G \alpha)$ sí y solo si para toda $i \geq 0$, $\pi^i \models \alpha$

Satisfacción para un modelo y un estado.

$M, s \models \alpha$ si $\pi_s \models \alpha$ para toda trayectoria π_s que sale de **s**

En este caso, alpha se cumple en el estado **s** de un modelo, si todas las trayectoria que salen de **s** hacen cierta alpha.

Ejemplos:

$M, s \models (a \wedge b)$: a y b son ciertas en s , porque tanto a como b son ciertas en el primer estado de todas las trayectorias que empiezan en s .

$M, s \models (X b)$: $X b$ es cierta en s , porque b es cierta en el segundo estado de todas las trayectorias que parten de s .

$M, s \not\models (F c)$: $F c$ no es cierta en todas las trayectorias que empiezan en s . En particular no es cierta la trayectoria que permanece en s hasta el infinito, nunca en el futuro aparece c en esa trayectoria.

$M, s \models (G b)$: $G b$ es cierta para M y s , porque se cumple en todos los estados de todas las trayectorias que salen de s .

Decimos que dos formas son lógicamente equivalentes entre sí, si para todo modelo y toda trayectoria de ese modelo, las trayectorias que hacen cierta a una fórmula también hacen cierta a la otra fórmula

$\alpha \equiv \beta$ si para todo modelo M y toda trayectoria π en M
 $\pi \models \alpha$ y $\pi \models \beta$

propiedades

$\neg F \alpha \equiv G \neg \alpha$	dualidad de F y G
$F(\alpha \vee \beta) \equiv F \alpha \vee F \beta$	F distribuye sobre $\vee$ disyunción
$G(\alpha \wedge \beta) \equiv G \alpha \wedge G \beta$	G distribuye sobre $\wedge$ conjunción

Satisfacción es, dada una fórmula α ¿existe un modelo M y un estado s de ese modelo que haga cierta a α o tal que $M, s \models \alpha$?

Verificación de modelos es, dados M, s y α , ¿ $M, s \models \alpha$?

El problema de **verificación de modelos** ha tenido un impacto enorme en la industria. Típicamente ya está dado y representa un sistema. Queremos saber si ese sistema tiene o no cierta propiedad representada por una fórmula α . Un **verificador de modelos** es un programa de computadora que nos dice si efectivamente el sistema tiene o no esa propiedad. Los **verificadores de modelos** pueden verificar sistemas muy grandes con diez a los veinte estados o a veces como diez a la 150 estados o más. Eso es más que el número de átomos del universo conocido.

Representan conjuntos de estados en fórmulas booleanas. Dos métodos que funcionan así son los diagramas binarios de decisión y los resolvers **SAT**. La aplicación principal de los verificadores de modelos es en la detección de errores de circuitos digitales. También en encontrar errores de programación.

Lógica de predicados

Conceptos preliminares y sintaxis de lógica de predicados

La **lógica de predicados** también se le conoce como **lógica de primer orden**. Sintaxis, semántica e inferencia. Un **predicado** es una **proposición**, como en la lógica proposicional, pero **parametrizada**. Es una **proposición parametrizada**. Por ejemplo, una **oración de predicados** sería,

Para **toda** x [**Si** iba-en-el-tren(x) y tiene-un-arma(x), **entonces** cometió-el-homicidio(x)].

Si le agregamos: iba-en-el-tren(**Sr-B**)

Por lo tanto podemos deducir que:

Si tiene-un-arma(**Sr-B**),

entonces cometió-el-homicidio(**Sr-B**)

Otra **oración con predicados**.

Para toda **y** [**Si** es-un-arma(**y**),

entonces existe **x** [es-dueño-de(**x,y**)]].

El lenguaje de la **lógica de predicados** es más elaborado que el de la lógica proposicional.

Presenta con tres **conjuntos** dados:

conjunto **X** de símbolos de **parámetro**

conjunto **Y** de símbolos de **función**

conjunto **P** de símbolos de **predicados**

En la sintaxis de **términos**, un término puede ser un símbolo de parámetro.

Símbolo de **parámetro** $x \in X$; símbolos de **función** $c, f \in F$

término es **x**

o **c**

o **f**(término, ... término)

símbolo de **parámetro**.

constante. Representa un objeto indivisible. Símbolo de **función**.

término compuesto. Símbolo de **función** con una sucesión de términos encerrados entre paréntesis y que representa un objeto compuesto.

Ejemplo en el que **x** y **y** son símbolos de parámetro

$X = \{x, y\}; F = \{c, f, g\}$

f(g(c), g(g(x)), y) Es un término compuesto con símbolo de función **F** y que tiene tres componentes.

Una fórmula puede ser:

Símbolo de predicado $P \in P$; símbolo de **parámetro** $x \in X$; símbolos de **función** $c, f \in F$

es $\top$

o $\perp$

o **P**(término, ... término)

o ($\neg$ fórmula)

o (fórmula $\wedge$ fórmula)

o ($\forall x$ fórmula)

o ($\exists x$ fórmula)

"**cima**" es una objeto sintáctico

"**fondo**" es una objeto sintáctico

predicado. Sucesión de términos entre paréntesis.

negación ("no")

conjunción ("y")

cuantificador universal. Precede a un símbolo de parámetro.

cuantificador existencial. Precede a un símbolo de parámetro.

Ejemplo:

$X = \{x\}; F = \{f\}; P = \{P\}$

($\forall x P(f(x))$)

Fórmula con símbolo de parámetro **X**, símbolo de función **F** y símbolo de predicado **P**.

el alcance de un cuantificador **seguido de un parámetro** $\forall x$ **seguido de una fórmula** $\forall x \alpha$ es esa fórmula α . el alcance de un cuantificador $\exists x$ **en** $\exists x \alpha$ es α .

ocurrencia **ligada** y ocurrencia **libre**.

ocurrencia **ligada** si está dentro del alcance de algún cuantificador.

ocurrencia **libre** si no dentro del alcance de algún cuantificador.

$(\exists x P(x)) Q(x)$

$\exists x (P(x) \wedge Q(x))$

fórmula cerrada o enunciado. No tiene ocurrencias libres.

Instancia de una fórmula. Nos dan un símbolo de parámetro x , una fórmula α y un término t .

una instancia $\alpha\{x := t\}$ de α es la fórmula que resulta de reemplazar todas las ocurrencias libres de x en α por t .

Por ejemplo:

$$\frac{P(f(x), x)}{\alpha} \{x := f(c)\} = P(f(f(c)), f(c))$$

$$\frac{\alpha}{\alpha} \quad \quad \quad t$$

Esta fórmula tiene dos ocurrencias libres de x y el resultado da reemplazarlas por f de c .

Semántica de lógica de predicados

Modelo (intuición)

¿es $1 + 1 = 10$ cierto?

Depende de la **situación** o **escenario** que vamos a **formalizar** en un **modelo**. Por ejemplo, si usamos base 10, falsa. Pero si usamos base 2, es cierta.

Un **modelo** (definición) M :

1. Un **conjunto** no vacío A , el universo de objetos
(**ejemplo**: N , el **conjunto** de los números naturales)
2. Por cada **símbolo de función** f , una función $f^M : A^n \rightarrow A$ que va del **conjunto** de **tuplas** de n **componentes** tomadas del universo al universo.
Ejemplo: el símbolo de más $+$ representa la suma de dos números naturales.
3. Por cada **símbolo de predicado** P , nos dan una **relación** sobre el universo A , i.e., un subconjunto $P^M \subseteq A^n$ es decir, un conjunto de tuplas de tamaño n de elementos del universo.
(por **ejemplo**, el símbolo igual $=$ podría corresponder a la identidad)

En el caso de $N = 0$, se trata de una constante y asociamos un elemento del universo a esa constante.

Es importante distinguir entre f y f con superíndice M . La f sin superíndice es un símbolo, mientras que la f con superíndice M es una función, similarmente con los símbolos de predicado.

Ligado al concepto de modelo está el concepto de **interpretación de un término sin símbolos de parámetro**.

Interpretación t^M de un término t sin símbolos de parámetro.

Si t es un **término simple** c , entonces la **interpretación** de c es el valor de c superíndice M . Es decir, el **elemento** que corresponde a c en el universo.

Interpretación de una constante c es c^M

Si t es un término compuesto con símbolo de función f , entonces debemos aplicar la función correspondiente a f a la interpretación de los componentes de t .

interpretación de un término $f(t_1, \dots, t_n)$ es $f^M(t_1^M, \dots, t_n^M)$

reescribimos $1 + 1 = 10$ como:

Es (más (uno, uno), diez)

En donde:

Es, es un símbolo de predicado con dos términos.

más, es un símbolo de función para términos con dos componentes.

uno, es una constante.

diez, es una constante.

Podemos anidar símbolos de función pero no símbolos de predicado.

Este modelo nos dice que el símbolo **1** representa el número uno. El símbolo **10**, representa el número diez. El símbolo $+$ representa la suma. Y el símbolo **Es** representa la **igualdad** entre números naturales.

Modelo 1

$A = \mathbb{N}$, el conjunto de los números naturales

$uno^M = 1$ $diez^M = 10$

$más^M = +$ $Es^M = \{(0, 0), (1, 1), (2, 2), \dots\}$

$(2, 10) \notin Es^M$ como la pareja 2, 10 no está en la relación asociada a Es, la oración no es cierta en este modelo.

Modelo 2

$A = \mathbb{N}$, el conjunto de los números naturales

$uno^M = 1$ $diez^M = 10$

$más^M = +$ $Es^M = \{(0, 0), (1, 1), (2, 2), \dots\}$

$(2, 2) \in Es^M$ como la pareja 2, 2 está en la relación asociada a Es, la oración hace cierta en este modelo.

Para propósitos de computación nos basta con tratar con fórmulas cerradas. Pueden tener símbolos de parámetro, pero esos símbolos deben ocurrir en el alcance de un cuantificador.

Supongamos las fórmulas α , β . Existe x gama y para toda x , gama cerradas. Y un predicado y un término.

Satisfacción de fórmulas cerradas

fórmulas α , β , $(\exists x \gamma)$ y $(\forall x \gamma)$ cerradas (sin ocurrencias libres)

predicado $P(t_1, \dots, t_n)$ sin símbolos de parámetro

término t sin símbolos de parámetro.

$M \models \top$ $M \not\models \perp$

$M \models P(t_1, \dots, t_n)$ sí y solo sí $(t_1^M, \dots, t_n^M) \in P^M$

$M \models (\neg \alpha)$ sí y solo sí $M \not\models \alpha$

$M \models (\alpha \wedge \beta)$ sí y solo sí $M \models \alpha$ y $M \models \beta$

Un predicado P de t_1 hasta t_n es cierto en M , si la tupla obtenida de interpretar cada t con respecto a M está en la relación asociada a P .

$M \models (\exists x \varphi)$ sí y solo sí para alguna t , $M \models \varphi\{x := t\}$

Una fórmula gama precedida de un cuantificador existencial de x es cierta en M sí y solo sí reemplazo x por algún término sin símbolos de parámetro resulta en una fórmula cierta en M .

Podemos pensar en el cuantificador existencial como una generalización de la **disyunción** para todo el universo.

$M \models (\forall x \varphi)$ sí y solo sí para toda t , $M \models \varphi\{x := t\}$

Una fórmula gama precedida de un cuantificador universal de x es cierta en M sí y solo sí reemplazando x por todos los términos sin símbolos de parámetro resulta en una fórmula ciertas en M .

Podemos pensar en el cuantificador universal como una generalización de la **conjunción** para todo el universo.

Conjunto de modelos que hacen cierta a una fórmula:

$M_{\text{cierto}}(\alpha) :=$ conjunto de modelos M que hacen cierta a una fórmula α .

$\alpha_1, \alpha_2, \dots, \alpha_n \models \beta$

$M_{\text{cierto}}(\alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_n) \subseteq M_{\text{cierto}}(\beta)$

un **conjunto de fórmulas lógicamente implica otra fórmula si** todos los **modelos que** hacen ciertas a todas las fórmulas del lado izquierdo están contenido en el **conjunto de modelos que** hacen cierto al lado derecho.

Recordar que el torniquete de satisfacción está recargado.

Equivalencia lógica

$\alpha \equiv \beta$ sí y solo sí $\alpha \models \beta$ y $\beta \models \alpha$

equivalencias

$\neg(\alpha \vee \beta) \equiv \neg\alpha \wedge \neg\beta$	dualidad de $\vee$ y $\wedge$
$\neg\exists x \alpha \equiv \forall x \neg\alpha$	dualidad de $\exists$ y $\forall$
$\exists x(\alpha \vee \beta) \equiv \exists x \alpha \vee \exists x \beta$	$\exists$ distribuye sobre $\vee$
$\forall x(\alpha \wedge \beta) \equiv \forall x \alpha \wedge \forall x \beta$	$\forall$ distribuye sobre $\wedge$


Inferencia de lógica de predicados

Las reglas de inferencia de la deducción natural son una generalización de las de la lógica de proposicional. Tenemos ahora reglas para la eliminación y la introducción de cuantificadores.

Deducción naturales

$\alpha \wedge \beta$	$\forall x \alpha$	
α	$\alpha\{x := t\}$	eliminación de $\forall x$

Podemos **eliminar** un cuantificador universal instanciando, es decir, si algo es cierto para todo posible valor de x , entonces también es cierto para un valor en particular de x . Esto es similar a la regla de **eliminación por conjunto**.



La introducción del cuantificador universal es un poco más delicada. Se encierra en un rectángulo una demostración auxiliar que empieza por introducir un valor arbitrario x_0 que no debe ocurrir fuera del rectángulo. Si podemos terminar con una fórmula α con ocurrencias de x_0 , entonces aunque x_0 sea un valor particular, como fue arbitrario, podemos reescribir α con el parámetro x en lugar del valor particular x_0 . Esto es similar a la regla de introducción por conjunción que deduce α y β a partir de α y de β . Aunque son solo dos fórmulas.

y otras más.

Usamos $\vdash$ para referirnos a **inferencia**.

$\alpha_1, \alpha_2, \dots, \alpha_n \vdash \beta$ si existen aplicaciones de reglas de inferencia que permiten convertir $\alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_n$ en β

completitud de la lógica de predicados

$\alpha_1, \alpha_2, \dots, \alpha_n \models \beta$

sí y solo sí

$\alpha_1, \alpha_2, \dots, \alpha_n \vdash \beta$ [Kurt Gödel, 1929]

satisfactibilidad para la lógica de predicados

satisfactibilidad para la lógica de predicados es indecidible

Es decir, no existe ni va a existir nunca un algoritmo que decida si una fórmula arbitraria de primer orden es satisfactible o no. [Alonzo Church, 1936; Alan Turing, 1937]

El problema SAT es NP-completo. Lo que significa que actualmente solo tenemos algoritmos que toman un tiempo exponencial.

Problemas cuando base de inteligencia artificial

- No definiciones inductivas (o sea, recursivas)
(solución: puntos fijos: programación lógica y Prolog)
- indecidible
(solución: lógica modal, lógica temporal)

- torpe con incertidumbre (solo $\forall$ y $\exists x$)
(solución: teoría de la probabilidad)
- monotonía: si $\alpha \models \beta$, entonces $\alpha \wedge \gamma \models \beta$
(solución: lógica “no monótonas”)
- problema del marco: representar todo lo que no cambia
(solución: cálculo de eventos, lógicas no monótonas ...)
- pensar lleva tiempo
(solución: **sistemas reactivos**)
- describir simbólicamente realidad
(solución: **redes** neuronales)

Teoría de la probabilidad

Introducción a la teoría de la probabilidad

Modelos gráficos: **redes bayesianas** y las cadenas de **Markov** de tiempo discreto.

Teoría de decisiones

Teoría de juegos

Una motivación para desarrollar la **teoría de la probabilidad** es observar que la lógica de primer orden es torpe para **representar incertidumbre**. Solo tiene la disyunción y el cuantificador existencial. Deseable un formalismo más rico para incertidumbre.

Hay varias **escuelas de pensamiento** en la teoría de la probabilidad, una de ellas es la escuela frecuentista que ve a la probabilidad como una propiedad de los eventos.

Para los **frecuentistas (objetiva)**, la probabilidad es la frecuencia con la que se da un evento, por lo tanto solo pueden asignar probabilidades a eventos que se repiten muchas veces o si no, eventos que puedan considerarse similares a otros eventos que sí se repiten. En ocasiones deben imaginar una muestra aleatoria, tomada de una población hipotética mayor que la que se tenga directamente.

La escuela **bayesiana (subjativa)** ve a la probabilidad como una medida del grado de certidumbre y por lo tanto la probabilidad es subjativa. Puede asignar probabilidades a eventos que no se repiten. La incertidumbre disminuye al hacer observaciones.

- Situaciones particulares (p. ej. lluvia hoy)
- medición del grado de certidumbre en creencias
- observaciones actualizan nuestro grado de certidumbre

A partir de estos tres axiomas podemos deducir todas las propiedades de la teoría de la probabilidad.

$0 \leq P(a) \leq 1$: la probabilidad es un número que varía entre cero y uno

$P(\text{cierto}) = 1$: la probabilidad del evento cierto es uno

$P(a \vee b) = P(a) + P(b) - P(a \wedge b)$: la probabilidad de que ocurra a o b es la suma de las probabilidades de cada uno menos la probabilidad de que ocurra tanto a como b.

teorema de Bayes

- ejemplo: homicidio en el tren
- examinamos a un viajero: $P(h) = 0.01$
- examinamos su pañuelo y vemos que tiene sangre
- **sangre en pañuelo de homicida** en 80% de los casos: $P(\text{sangre} | \text{homicida}) = 0.80$
- **sangre en pañuelo de no homicida** en 10% de los casos

probabilidad condicional y probabilidad conjunta

- $P(s | h) = 0.80$
- $P(s \wedge h) = P(s | h) * P(h) = 0.80 * 0.01 = 0.008$

Si suponemos **1000** personas un **1%** por ciento, o sea **diez** son homicida. El **80%** de ellos osea **ocho** tienen sangre en el pañuelo. A esta **ecuación** le vamos a llamar **regla de la multiplicación**.

Muchos autores ven a la probabilidad condicional como fundamental y la probabilidad conjunta como una probabilidad derivada. Si queremos ver la probabilidad conjunta como fundamental podemos auxiliarnos de los diagramas de **Venn**.



Este espacio de **eventos** tiene **área** uno, por lo que la **probabilidad** de a es el **área** de este círculo y similarmente para b. El **área** entre la **intersección** de ambos círculos es la **probabilidad conjunta a y b**. Para calcular la **probabilidad de a dado b**, debemos normalizar con **respecto a la probabilidad de b**. Es decir, **dividimos** el área de la intersección entre **P(b)**.

teorema de Bayes

- ejemplo: homicidio en el tren
- examinamos a un viajero: **P(h) = 0.01**
- examinamos su pañuelo y vemos que tiene sangre
- **sangre en pañuelo de homicida** en 80% de los casos: **P(s | h) = 0.80**
- **sangre en pañuelo de no homicida** en 10% de los casos

0.01 homicida: P(h)

0.80 sangre $0.01 * 0.80 = 0.008$ homicida y con sangre en el pañuelo: **P(h|s)**

0.20 no sangre $0.01 * 0.20 = 0.002$ homicida y no sangre en el pañuelo: **P(h|¬s)**

0.99 no homicida: P(¬h)

0.10 sangre $0.99 * 0.10 = 0.099$ no homicida y con sangre en el pañuelo: **P(¬h|s)**

0.90 no sangre $0.99 * 0.90 = 0.891$ no homicida y no sangre en el pañuelo: **P(¬h|¬s)**

supongamos 1000 personas

hay 10 homicidas (1%) y 990 (99%) no homicidas

hay 8 homicidas ($1\% * 80\%$) + 99 ($99\% * 10\%$) no homicidas = **P(h | s) + P(¬h | s) = 107** con sangre en el pañuelo de estas **107** personas con sangre, 8 son homicidas.

La probabilidad de que el viajero sea homicida dado que su pañuelo tiene sangre es: $8/107 = 0.07$

Vamos a calcular con el **teorema de Bayes** la **probabilidad de h dado s**.

$$P(h|s) = P(h \wedge s) / P(s); \quad P(s|h) = P(s \wedge h) / P(h)$$

$$P(h \wedge s) = P(h|s) * P(s) = P(s|h) * P(h) \leftarrow \text{regla de multiplicación}$$

$$P(h|s) = P(s|h) * P(h) / P(s) \leftarrow \text{teorema de Bayes}$$

$$\begin{aligned} P(\text{homicida} | \text{sangre}) &= P(\text{sangre} | \text{homicida}) * P(\text{homicida}) / P(\text{sangre}) \\ &= 0.80 * 0.01 / 0.107 = 0.07 \end{aligned}$$

$$P(\text{sangre} | \text{homicida}) = 0.80 \quad P(\text{homicida}) = 0.01$$

no tenemos $P(s)$ pero la podemos calcular:

$$P(s) = P(s \wedge h) + P(s \wedge \neg h) \leftarrow \text{marginalización}$$

$$\begin{aligned} P(\text{sangre}) &= P(\text{sangre} \wedge \text{homicida}) + P(\text{sangre} \wedge \neg \text{homicida}) \\ &= P(\text{sangre} | \text{homicida}) * P(\text{homicida}) + P(\text{sangre} | \neg \text{homicida}) * P(\neg \text{homicida}) \\ &= 0.80 * 0.01 + 0.099 * 0.99 = 0.107 \end{aligned}$$

En resumen tenemos **tres fórmulas** que son la **base del razonamiento probabilístico**:


$$P(h \wedge s) = P(h|s) * P(s) = P(s|h) * P(h) \leftarrow \text{regla de la multiplicación}$$

$$P(h|s) = P(s|h) * P(h) / P(s) \leftarrow \text{teorema de Bayes}$$

$$P(s) = P(s \wedge h) + P(s \wedge \neg h) \leftarrow \text{marginalización}$$

Redes bayesianas

El ejemplo anterior se puede ver como una **red Bayesiana**. Tiene **dos nodos** uno por cada variable y **una flecha** que va del **nodo homicida** al **nodo sangre**. Decimos que el homicida es padre del nodo sangre. Además, **cada nodo tiene una tabla de probabilidad condicional** que nos dice la **probabilidad** de una variable considerando el efecto de los padres, si es que los hay, de ese nodo.



La **probabilidad** de nuestro personaje sea homicida es 0.01 y de que no lo sea 0.99. También nos dieron la **probabilidad** de que un homicida tenga sangre en su pañuelo del 80% y la **probabilidad** de que un no homicida haya tenido una hemorragia nasal del 10%. La **probabilidad** de que el pañuelo tenga sangre **está dada en términos de la variable** homicida, por eso dibujamos la flecha así.

Si aplicáramos el **teorema de Bayes** podríamos calcular las **probabilidades** de homicida dada sangre y **podríamos entonces dibujar una flecha al revés**, de sangre a homicida.

Un concepto central en las **redes bayesianas** es el de **independencia**. Dos **eventos a y b** son **independientes** si la **probabilidad de a dado b es igual a la probabilidad de a**.

$$P(a|b) = P(a)$$

La **probabilidad condicional**, esto equivale a decir que **la relación** que guarda el **área azul con respecto a P de b** es la misma **relación** que guarda el **área de P de a, con respecto al área del espacio muestral**.

$$P(a | b) = P(a)$$

$$P(b | a) = P(b)$$

$$P(a \wedge b) = P(a) * P(b)$$

$$\text{En general, } P(a \wedge b) = P(a | b) * P(b)$$

Equivalentemente se cumple que **P de b dado a** es igual a **P de b**, o que la **probabilidad** de la **conjunción** de **a y b** se obtiene multiplicando las **probabilidades incondicionales** de **a y de b**. Es decir, que **la probabilidad de que ocurra b no depende si ocurrió a o no**.

La **independencia condicional** dice exactamente lo mismo, en lugar de calcular las probabilidades con respecto al **espacio muestral**, se calculan con respecto a la **probabilidad de c**.


$$P(a | b \wedge c) = P(a | c) \text{ o}$$

$$P(b | a \wedge c) = P(b | c) \text{ o}$$

$$P(a \wedge b | c) = P(a | c) * P(b | c)$$

$$\text{En general, } P(a \wedge b | c) = P(a | b, c) * P(b | c)$$

Agregando la variable cuchillo. Ahora la **probabilidad** de que alguien tenga un cuchillo en su compartimento, **dado que es un homicida** es de 85%. **Pero** algunas personas que no son homicidas también tienen un cuchillo.



Esta **red bayesiana** indica que sangre y cuchillo **son condicionalmente independientes** dado homicida.

Un **evento atómico** es la **conjunción** de todas las variables de la **red** posiblemente **negadas**. Es decir, es una idea similar a la de modelo en **lógica proposicional**.

Ejemplos (8):

cuchillo $\wedge$ **sangre** $\wedge$ **homicida**

cuchillo $\wedge$ **sangre** $\wedge$ $\neg$ **homicida**

cuchillo $\wedge$ $\neg$ **sangre** $\wedge$ **homicida**

cuchillo $\wedge$ $\neg$ **sangre** $\wedge$ $\neg$ **homicida**

$\neg$ **cuchillo** $\wedge$ **sangre** $\wedge$ **homicida**

$\neg$ **cuchillo** $\wedge$ **sangre** $\wedge$ $\neg$ **homicida**


$\neg$ **cuchillo** $\wedge$ $\neg$ **sangre** $\wedge$ **homicida**

$\neg$ **cuchillo** $\wedge$ $\neg$ **sangre** $\wedge$ $\neg$ **homicida**

La **distribución conjunta completa** indica la **probabilidad** de cada **evento atómico**. Por ejemplo, la **distribución conjunta completa** para nuestro ejemplo sería esta en forma de **tabla**.


	sangre		$\neg$ sangre	
	cuchillo	$\neg$ cuchillo	cuchillo	$\neg$ cuchillo
homicida	0.0068	0.0012	0.0017	0.0003
$\neg$ homicida	0.0248	0.0742	0.2228	0.6682

Aquí en forma de diagrama.




Los **eventos atómicos** particionan el **espacio muestral**. En este ejemplo el **espacio muestral** se particiona en **ocho eventos atómicos** dependiendo de cuáles variables sean ciertas y cuáles falsas.

Por ejemplo, el **evento atómico** cuchillo, no sangre y no homicida es el área de esta **luna** marcada.



Es claro que si tenemos la **distribución conjunta completa** podemos contestar cualquier pregunta sobre las variables de la **red**. Por otro lado, una **red bayesiana** **tiene toda la información necesaria para calcular la distribución conjunta completa**. Entonces podemos ver una **red bayesiana** como una representación concisa de la **distribución conjunta completa**.



Por lo tanto, también podemos contestar cualquier pregunta sobre las variables de la **red**, a partir de las **tablas de probabilidad condicional**. Una manera, es a través de la **distribución conjunta completa**. Para esto, vamos a introducir la regla de la **cadena**.

Esta regla se puede obtener a partir de la **regla de la multiplicación** aplicada a una **conjunción** de varias variables y aplicándola sucesivamente varias veces. Nos queda entonces que la **probabilidad** de una **conjunción** de variables es este **producto**.

Regla de la cadena

generalizamos la **regla de la multiplicación**

$$P(a \wedge b) = P(a | b) * P(b)$$

a conjunción de varias variables (usamos coma en lugar de $\wedge$)

$$P(x_1, \dots, x_n) = P(x_1 | x_2, \dots, x_n) * P(x_2, \dots, x_n)$$

aplicamos sucesivamente

$$\begin{aligned} P(x_1, \dots, x_n) &= P(x_1 | x_2, \dots, x_n) * P(x_2 | x_3, \dots, x_n) * \dots * \\ &= P(x_{n-1} | x_n) * P(x_n) \\ &= \prod_{i=1}^n P(x_i | x_{i+1}, \dots, x_n) \end{aligned}$$

Regla de la cadena + independencia condicional

$$\begin{aligned} P(x_1, \dots, x_n) &= \prod_{i=1}^n P(x_i | x_{i+1}, \dots, x_n) \\ &= \prod_{i=1}^n P(x_i | \text{padres}(x_i)) \end{aligned}$$

donde $\text{padres}(x_i)$ preserva el signo de $x_{i+1}, \dots, x_n$.

La idea más importante para hacer inferencia es que **podemos calcular la probabilidad de esta conjunción utilizando únicamente las tablas de la probabilidad condicional**.

Ejemplo de **probabilidad condicional** de **evento atómico**:
cuchillo, no sangre y no homicida.

$$\begin{aligned} P(\text{cuchillo}, \neg \text{sangre}, \neg \text{homicida}) &= P(\text{cuchillo} | \neg \text{homicida}) * P(\neg \text{sangre} | \neg \text{homicida}) * P(\neg \text{homicida}) \\ &= 0.25 * 0.9 * 0.99 \\ &= 0.2228 \end{aligned}$$

Donde $P(c | \neg h) = 0.25$, $P(\neg s | \neg h) = 0.9$ y $P(\neg h) = 0.99$
se obtienen de las tablas de probabilidad condicional.

Observar que:

h es padre de **s** y **c**

h está negado en las condiciones por está negado en la conjunción.

Conjunciones no atómicas. Teníamos la **marginalización** con respecto a una sola variable **h**. Nos conviene ahora generalizarla a todas las variables de la **red** que no aparecen en la **conjunción** de $X_k + 1$ a X_n .

Conjunciones no atómicas generalizamos **marginalización**

$$P(s) = P(s \wedge h) + P(s \wedge \neg h)$$

a **eventos atómicos**

$$P(x_1, \dots, x_k) = \sum_{\{x_{k+1}, \dots, x_n\}} P(x_1, \dots, x_k, x_{k+1}, \dots, x_n)$$

Σ = Unión o suma

Esta **sumatoria** es con respecto a todos los posibles valores de estas variables.
(2^{n-k} sumandos para $n - k$ variables booleanas)

ejemplo de **probabilidad de conjunción no atómica**

$$\begin{aligned} P(s) &= P(s, h, c) + P(s, \neg h, c) + P(s, h, \neg c) + P(s, \neg h, \neg c) \\ &= 0.0068 + 0.0248 + 0.0012 + 0.0743 = 0.107 \end{aligned}$$

observar que:

aparecen todos los valores posibles de **h** y **c**

estas cuatro probabilidades se calculan con la regla de la cadena + independencia condicional.

Probabilidad condicional.

Generalizamos probabilidad condicional

$$P(h | s) = P(h, s) / P(s)$$

a **conjunciones**

$$P(x_1, \dots, x_k | y_1, \dots, y_d) = P(x_1, \dots, x_k, y_1, \dots, y_d) / P(y_1, \dots, y_d)$$

La podemos reescribir como el cociente de dos probabilidades de conjunciones.

Ejemplo **probabilidad condicional**

$$\begin{aligned} P(h | s, c) &= P(h, s, c) / P(s, c) \\ &= 0.0068 / 0.0316 = 0.2156 \end{aligned}$$

que podemos calcular con lo visto para **conjunciones**.

En general una **red bayesiana** es una gráfica sin ciclos. El problema de inferencia en una **red bayesiana** es en general tan **difícil como calcular el número de modelos** que hacen cierta una **fórmula proposicional**. Es decir, es por lo menos tan **difícil como los problemas NP-completos**.

Teoría de la probabilidad parte 2

Cadenas de Markov

Las **cadenas de Markov** son un formalismo matemático para describir **variables aleatorias** que **cambian** en el **tiempo**. Un **estado** es una asignación de valores para un conjunto de variables.

Para ilustrarlo imaginemos un tren inteligente: ¿**Qué variables son relevantes** para un tren inteligente? El **número de pasajeros**. Un **valor particular** de esta variable podría ser 500. Otra **variable relevante** es si **está lloviendo** o **no** está lloviendo.

Decimos que un **estado** es observable si puede **medirse** o puede **conocerse** con certidumbre.

Una lotería es un experimento aleatorio del que no podemos anticipar el resultado. Por ejemplo, no podemos saber antes de lanzar una moneda si va a caer sol o águila.

La **medida de probabilidad** es una **función** que asigna las **probabilidades** a los **eventos**. Permite **cuantificar de manera consistente la incertidumbre**. Una **variable aleatoria** toma valores del resultado de una lotería.

Para ilustrar una **variable aleatoria** regresemos al ejemplo del tren inteligente. En el tren inteligente nos interesa conocer en qué vagón viaja un pasajero.

Tenemos una **variable b** y puede tomar uno de **tres valores**,


el vagón **dormitorio**,

el vagón **comedor** o

el vagón **bar**.

Ahora **seleccionamos aleatoriamente** un pasajero, del pasajero no nos interesa su identidad sino solamente el **vagón** en el que viaja. Esto es una lotería.

La **variable aleatoria** que denominamos **b** puede tomar tres valores posibles, cada una de las tres etiquetas definidas. Este **diagrama de árbol** **ilustra** cada salida en una **rama** etiquetada con la probabilidad correspondiente.



Un **proceso estocástico** formaliza matemáticamente la **evolución temporal** de un **conjunto** de **variables aleatorias**. Podemos pensar esto como un **ensamble** de **variables parametrizadas** por un **parámetro** o **índice** y este índice representa el **tiempo**. Cada variable toma su valor de un espacio de estado cese y es la realización de un experimento aleatorio en un **espacio muestral numérico**.

El tipo más simple de **proceso estocástico** es el **proceso de Bernoulli**.

Pensemos por ejemplo en lanzar una moneda repetidas veces. Las **variables aleatorias** serán la cara visible de la moneda tras cada lanzamiento. El **espacio de estado** es **águila** o **sol**. Lanzamos la moneda,

el **primero estado** de nuestra **variable** es **águila**, siguiente **estado** sol, **siguiente** águila, **luego** águila otra vez, **seguido** por sol, otra vez sol, etcétera.

En un **proceso de Bernoulli** la **probabilidad del estado** siguiente no depende del **estado actual**. En modelos más ricos podemos definir una regla de evolución temporal.

En un **proceso estocástico de Markov** el **índice** representa el **tiempo** y también este proceso exhibe la **propiedad markoviana** o de Markov. Esta **propiedad** lo que dice es que la **probabilidad de observar un estado en el tiempo** siguiente solo **depende del presente** y **no** de los **estados** observados en el **pasado**.

En las **cadenas de Markov** tenemos **estados finitos** y **tiempo discreto**. La **propiedad de Markov** nos dice de que la **probabilidad de la variable aleatoria x** se realice en el **estado s** en el **tiempo siguiente** dada toda la historia de **estados** observados **s1, s2** hasta **s_t**, **es igual** a la **probabilidad** de observar el **estado s** dado el **estado** en el **tiempo presente s_t**.


En la **propiedad de Markov** podemos olvidar el pasado pues este no tiene repercusión en lo que sucederá en tiempos futuros, puesto que tanto el **tiempo** como los **estados** son **discretos**:

$$P(X_{t+1} = s \mid X_1 = s_1, \dots, X_t = s_t) = P(X_{t+1} = s \mid X_t = s_t)$$

Vamos a presentar un ejemplo de la aplicación de la **cadena de Markov** al problema de la **localización probabilística** de un pasajero en el tren. Comenzamos por identificar los **estados**.

El **primer estado** es el **vagón dormitorio** que representamos con el vértice etiquetado con la letra d. El **siguiente** es el **bar**, el **siguiente** el **comedor**.

Ahora bien, las aristas dirigidas de nuestro grafo van a ilustrar la **relación de parejas de estados presentes y futuros** siempre que la **probabilidad** sea distinta de 0. Si la probabilidad es 0 la arista no existe. En nuestro ejemplo, si el pasajero **se encuentra en el vagón dormitorio**, la **probabilidad de que en el minuto siguiente continúe en el dormitorio es igual a 0.7**. Así dibujamos esta arista con origen y destino en el **nodo d**. Etiquetamos la arista con su parámetro o probabilidad de transición. Formalmente la probabilidad de que en el tiempo **t+1** el estado sea el dormitorio dado que en el tiempo actual el estado es **dormitorio** es de **0.7**.




Otra **posibilidad** es que el pasajero vaya al **bar**. Agregamos la arista con su parámetro igual a **0.1**. La transición del **dormitorio** al **comedor** con **probabilidad 0.2**. Completamos el grafo con las probabilidades restantes. **La conveniencia de este diagrama de estados es que no representamos el tiempo de manera explícita dado que las probabilidades son estacionarias**. El diagrama de **estados** puede ser muy conveniente para un modelador humano. Pero nuestra gente no es humano. Matemáticamente para describir la **cadena de Markov** es más adecuado utilizar una representación **matricial**.

Las **probabilidades de transición** pueden representarse de manera **matricial**:

$$T = \begin{bmatrix} 0.7 & 0.4 & 0.2 \\ 0.1 & 0.4 & 0.2 \\ 0.2 & 0.2 & 0.6 \end{bmatrix}$$


Con entradas:

$$P_{ij} \equiv P(X_{t+1}=i \mid X_t=j)$$




En esta **matriz** las **entradas** son las **probabilidades de transición de estado**, aquí el índice de las **entradas** asociado al renglón corresponde con el **estado** siguiente y el **índice** asociado a la **columna** con el **estado presente**. Por ejemplo, si el índice 1 es para el **estado d**, el índice 2 para el **estado b** y el índice 3 para el **estado c**, entonces la entrada 1,1 de la matriz es la **probabilidad** de que un **agente** en el **estado d** **continúe en dicho estado al tiempo siguiente**. La entrada 1,2 es la **probabilidad** de transitar de **b** a **d**. La entrada 1,3 la probabilidad de transitar de **c** a **d**. Observamos que el primer renglón define la **probabilidad** de cada una de las maneras de transitar al **estado d**.

La **entrada 2,1** la **probabilidad** de transitar de **d** a **b**. La **2,2** la **probabilidad** de estar y permanecer en **b**. **2,3** la **probabilidad** de transitar de **c** a **b**. **3,1** la probabilidad de transitar de **d** a **c**. **3,2** la **probabilidad** de transitar de **b** a **c**. Y finalmente **3,3** la **probabilidad** de estar y permanecer en **c**.



La **evolución de la distribución de probabilidad** sobre los **estados** del problema está gobernada por la **ecuación matricial** aquí mostrada. En el lado izquierdo hemos conformado un **vector** con las **probabilidades** de cada **estado** al tiempo siguiente. Del lado derecho tenemos el producto de la **matriz** T de **probabilidades** de transición, con el **vector** cuyas **entradas** son las **probabilidades** de los **estados** al tiempo actual.



Podemos usar la **regla de evolución** para anticipar **cómo cambiará una distribución de probabilidad en tiempos futuros**. Si sabemos con servidumbre que el pasajero se encuentra en el **vagón dormitorio**, es decir el **estado 1**, esto se representa **vectorialmente** con el **vector de distribución de probabilidad 1,0,0** al cual por brevedad denotaremos simplemente como **P0**.


Si sabemos que el pasajero se encuentra en el dormitorio al tiempo $t = 0$:

$$P(X_0) = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \equiv P_0$$

Al tiempo siguiente la distribución es:

$$P(X_1) = T P_0 \equiv P_1$$

$$P_1 = \begin{bmatrix} 0.7 & 0.4 & 0.2 \\ 0.1 & 0.4 & 0.2 \\ 0.2 & 0.2 & 0.6 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

$$= \begin{bmatrix} 0.7 \\ 0.1 \\ 0.2 \end{bmatrix}$$


probabilidades de transición de estado por el vector P_0 obtendremos la distribución

Entonces la **regla de evolución** nos dice que, al **multiplicar** la **matriz de probabilidades de transición de estado** por el **vector P_0** , obtendremos la **distribución de probabilidad** para los **estados** en el **tiempo** siguiente t igual a **1**. Al realizar el **producto matricial** obtenemos que la **distribución de tiempo t igual a 1** es **0.7, 0.1, 0.2**. Esto indica que es muy probable que la gente continúe en el **estado d**, pero existe una probabilidad de **0.1** de que se encuentre en **b** y de **0.2** de que se encuentre en **c**.

Ahora, ¿qué pasa si deseamos conocer la **distribución de probabilidad** al **tiempo t igual a 2**? Observamos que basta iterar la ecuación una vez más. Esto es una vez que obtenemos **p1**, **p2** se obtiene **multiplicando t por p1**. En este caso, el **producto** nos da el **vector 0.57, 0.15, 0.28**

Observamos que si sustituimos **p1m** por el **producto matricial t por p0**, entonces una expresión equivalente es **eleva al cuadrado la matriz de probabilidades de transición y multiplicarla por la condición inicial**.

Para tiempos futuros:

$$P(X_t) = TP(X_{t-1}) \equiv P_t$$


$$P_1 = TP_0$$

$$P_2 = TP_1$$

$$= \begin{bmatrix} 0.7 & 0.4 & 0.2 \\ 0.1 & 0.4 & 0.2 \\ 0.2 & 0.2 & 0.6 \end{bmatrix} \begin{bmatrix} 0.7 \\ 0.1 \\ 0.2 \end{bmatrix}$$

$$= \begin{bmatrix} 0.57 \\ 0.15 \\ 0.28 \end{bmatrix}$$

$$= TTP_0 = T^2P_0$$




Esto es una vez que obtenemos p1,
p2 se obtiene multiplicando t por p1.

Esta es una **regla general**. Si deseamos conocer la **distribución de probabilidad t** pasos de tiempo al futuro, **basta** con **eleva** la **matriz t** al **tiempo t**.


Para tiempos futuros:

$$P_t = T^t P_0$$



basta con elevar la matriz t al tiempo t.

Aquí el **vector** traspuesto para **t** igual a 1. Para **t** igual a 2, para **t** igual a 3, para **t** igual a 4. Observamos que a dos dígitos significativos el **vector** ya no cambia para **tiempos iguales o mayores** a **t** igual a 5. El que la **distribución** converja no es accidente, a la **distribución resultante** se le conoce como **distribución de estado estable**.



Aún más interesante es que la **distribución de estado estable** no depende de la **condición inicial**, recordando que los **vectores característicos** son aquellos que **no cambian de dirección** ante una **transformación lineal**. Otro método para encontrar la **distribución de estado estable** es encontrar los **vectores** característicos de la **matriz** de **transición t**.

Teoría de decisiones

Como detectives, tenemos a nuestra disposición una prueba de ADN, que vamos a suponer que es infalible. Realizar esa prueba tiene un **costo de 100**. Además, si efectivamente la prueba de ADN sale positiva, significa que hemos descubierto al homicida y recibimos una **recompensa de 1000**.


Podemos **decidir entre hacer y no** hacer la prueba de ADN. Vamos a suponer que la **probabilidad** de que encontremos al **homicida** es **0.2**. También suponemos que nuestras preferencias coinciden con la cantidad de dinero que obtenemos. Esta situación se puede **representar** con un **árbol de decisiones**, en el que tenemos que tomar la **decisión de hacer o no** la prueba de ADN.

Si decidimos realizarla, hay **dos posibilidades**, que hayamos **descubierto o que no** hayamos descubierto al homicida. Si la prueba resulta **positiva**, o sea, que sí lo descubrimos, nuestra ganancia es **1000** de la recompensa **menos 100** de la prueba de ADN. Si la prueba resulta **negativa**, nuestra ganancia es **-100**. Finalmente, si decidimos **no hacer la prueba**, nuestra ganancia es **cero**.



Los **nodos** que representan **decisiones** nuestras van a ser **cuadrados**. Los **nodos** que representan **posibilidades** que no están bajo nuestro control, digamos que es la naturaleza quien decide, van a ser **círculos**. Las **hojas** van a ser **triángulos**.

Consideramos las **probabilidades** de que descubramos o no al homicida, que son **0.2** y **0.8**. Ahora evaluamos el **árbol**, es decir, le damos valores a los **nodos**.



A este **nodo circular** lo etiquetamos con la ganancia esperada, que es $900 * 0.2 - 100 * 0.8$, que nos da **100**. Eso significa que en un mundo extraño en el que pudiéramos repetir muchas veces este experimento, en promedio, a la larga, ganaríamos **100**. Vemos entonces que **lo que más nos conviene** es sí hacer la prueba de ADN. Los **cuadrados** se evalúan entonces con el **máximo** de sus hijos.

Vamos a elaborar un poco el ejemplo. Ahora tenemos acceso a una **base de datos** de huellas digitales que cuesta **20**. Pero esta **base de datos** no es perfecta como el análisis de ADN, la **probabilidad** de que las huellas del sospechoso **estén en la base de datos** es alta, **0.9**. La **probabilidad** de que la base de datos **se equivoque** y nos diga que sí se trata de un homicida cuando no lo es, es **0.4**.

$$\begin{array}{ll}
 P(h) = 0.2 & P(\neg h) = 0.8 \\
 P(b|h) = 0.9 & P(\neg b|h) = 0.1 \\
 P(b|\neg h) = 0.4 & P(\neg b|\neg h) = 0.6
 \end{array}$$

$$\begin{aligned}
 P(b) &= P(b|h) \times P(h) + P(b|\neg h) \times P(\neg h) \\
 &= 0.9 \times 0.2 + 0.4 \times 0.8 = 0.5
 \end{aligned}$$

$$P(h|b) = \frac{P(b|h) \times P(h)}{P(b)} = \frac{0.9 \times 0.2}{0.5} = 0.36$$

$$P(h|\neg b) = \frac{P(\neg b|h) \times P(h)}{P(\neg b)} = \frac{0.1 \times 0.2}{0.5} = 0.04$$

Aquí, del lado izquierdo, están las **probabilidades dadas**. Del lado derecho están los **complementos**.

Calculamos primero con **marginalización** la **probabilidad** de que la base de datos **diga que sí** trata de un homicida. Nos da **0.5**.

$$\begin{aligned}
 P(b) &= P(b|h) * P(h) + P(b|\neg h) * P(\neg h) \\
 &= 0.9 * 0.2 + 0.4 * 0.8 = 0.5
 \end{aligned}$$


Ahora, **aplicando el teorema de Bayes**, calculamos de manera similar a como lo hicimos con el pañuelo con sangre, la **probabilidad** de que el **sospechoso sea el homicida**, **dado** que la **base de datos** dice que **sí** lo es.

$$\begin{aligned}
 P(h|b) &= P(b|h) * P(h) / P(b) \\
 &= 0.9 * 0.2 / 0.5 = 0.36
 \end{aligned}$$

También calculamos la **probabilidad** de que sea el **homicida**, dado que la **base de datos** dice que **no** lo es cierto.

$$P(h | \neg b) = P(\neg b | h) * P(h) / P(\neg b)$$

$$= 0.1 * 0.2 / 0.5 = 0.04$$



El **árbol de decisiones** tiene ahora **dos decisiones**. Si sí decidimos hacer la prueba de ADN pero no usamos la base de datos, tenemos el **árbol** que ya vimos y que representamos con este triángulo. La ganancia esperada era **100**.

Ahora tenemos una **tercera posibilidad** que es usar la **base de datos**. Sigue un **nodo** que no depende de nosotros y, con **probabilidad** de **0.5**, la **base de datos** puede decir que sí se trata del homicida o que no. En ambos casos, podemos decidir hacer o no hacer la prueba de ADN. Si decidimos no hacerla, perdemos solo **20** pesos. Si decidimos sí hacerla, hay una **probabilidad** de **0.36** de que, efectivamente, el sospechoso sea el homicida, en cuyo caso ganamos **1000** y perdemos **120**. Es la **probabilidad** de **h** **dado b**, porque seguimos el camino en el que **b** vale **cierto**.

Si el sospechoso resulta **no ser el homicida**, perdemos **120** pesos. Esto es con **probabilidad** de **0.64**. Finalmente, agregamos las **probabilidades** de que el sospechoso sea el homicida, dado que la **base de datos** dice que no lo es y de que no sea el homicida. Esto es porque llegamos aquí con la rama en la que **b** vale **falso**.

Evaluamos el **árbol** con los valores esperados en los **círculos** y el máximo en los **cuadrados**. Vemos que la ganancia esperada es de **110** pesos. Nos conviene más sí usar la base de datos, pues de otra manera la ganancia esperada es menor, **100** pesos.

Luego, si la base de datos dice que las huellas del sospechoso sí están en la base de datos, nos conviene sí hacer la prueba de ADN, en cuyo caso la ganancia esperada es de **240** pesos. En cambio, si la base de datos dice que no se trata de un homicida, nos conviene más no hacer la prueba de ADN con una ganancia esperada de **-20** pesos.

Terminamos con la **utilidad del dinero**. En estos ejemplos, asumimos que nuestra **apreciación** del dinero, es decir, la **utilidad** del dinero, **era lineal** con respecto al dinero. Sin embargo, típicamente esto no es cierto. Algunos investigadores, aunque no todos, argumentan que mientras más dinero tiene una persona, menos aprecia al dinero adicional, relativamente hablando. Para estos investigadores, la **utilidad varía de manera similar al logaritmo** del dinero.




Otro fenómeno importante es que, por lo regular, **los humanos toman más en serio las pérdidas que las ganancias**. Esto también se ve reflejado en esta gráfica, pues **la utilidad decrece más rápidamente** al movernos hacia la izquierda de lo que crece al movernos a la derecha. Hasta aquí no hay nada de irracional. **Nuestras preferencias de dinero pueden depender de la cantidad de dinero que tengamos**.

Por último, observamos que **una función de utilidad cóncava vista desde abajo**, como esta, implica una preferencia por situaciones en las que no hay riesgo.

Supongamos una apuesta en la que se tira una moneda al aire. Si la moneda cae de un lado, ganamos un peso. Si cae del otro, ganamos 11 pesos. Sin embargo, pocas personas están dispuestas a pagar seis pesos por jugar este juego. El valor esperado, o sea, lo que ganaríamos después de muchas repeticiones, en promedio es seis pesos.

Entonces, **la mitad de las veces la utilidad** va a ser **A** y la **otra mitad de las veces** va a ser **B**, en **promedio**. La **utilidad** esperada es **entonces** un poco menor a la **utilidad** de seis pesos. Se dice entonces que tenemos **aversión al riesgo**.



Teoría de la probabilidad parte 3

Procesos de Decisión de Markov

Los **procesos de adhesión de Márkov** son un formalismo matemático para la toma de **decisiones en entornos con incertidumbre**. Los **procesos de adhesión de Markov** son una **extensión** de las **cadenas de Markov** donde vamos a incorporar las **acciones** del **agente**. El **agente**, a través de las **acciones**, va a poder cambiar las **probabilidades de transición de estado**. Las **acciones** se toman de acuerdo a una **política**.

La **política** es una **función** que le dice a la gente, dado un estado, **qué acción le conviene tomar**. Si el **agente** trata de maximizar una **función de utilidad**, se dice que este **agente** es un **agente racional**.

En los problemas de adhesión secuenciales, existen varias formas de definir la política óptima. Una de ellas es **considerar** que el **agente** solo trata de maximizar la **utilidad** del **estado siguiente**. Esta se le conoce como **política miope**.

Una segunda forma de definirlo es **considerar** una **ventana de tiempo**. Por ejemplo, consideremos no solo la **utilidad** de **mañana**, sino de **pasada mañana**, y así durante toda la **semana**.

Una tercera forma es **considerar todos los tiempos futuros**. A esta **política** se le conoce como de **horizonte infinito**, y es la más fácil de tratar matemáticamente.


Anteriormente, ya utilizamos **cadenas de Markov** para modelar **procesos estocásticos**. Ahora vamos a aumentar las **cadenas de Márkov** con una **función** que **asigna** a cada **estado** una **utilidad**.

Observamos que la **probabilidad** de llegar a un **estado** al **tiempo** siguiente solo depende del **estado** en el que nos encontramos en el tiempo actual.

Representamos la **cadena de Markov** con un grafo de **transición de estados**. Definimos una **utilidad** para cada **estado** posible. En nuestro ejemplo podría ser el consumo promedio por unidad de tiempo en cada uno de los vagones. Para el **vagón comedor**, 27. Para el **bar**, 10. En el **dormitorio** no hay consumo.

En adelante usaremos la letra **R** en lugar de la letra **U**. La **R** significará **recompensa**. A la **recompensa** de un **estado** la denotamos como **recompensa instantánea**. Considerando que nos interese encontrar una **política horizonte infinito**, plantearemos una **utilidad** que integre el valor esperado de **utilidad** para todos los **estados** futuros. El valor de la **recompensa** en tiempos futuros se verá **afectado** por un **factor de depreciación** o **descuento**.


Una **recompensa** vale más hoy que mañana, y vale más **mañana** que **pasado mañana**.



Aún no tomamos en cuenta las **acciones** del **agente**, pero eso lo haremos más adelante. Recordemos que para una lotería podemos calcular su **utilidad** sumando los **productos** de las **utilidades** de las salidas con su **probabilidad** respectiva. Aquí podemos plantear la **utilidad** de un **estado** de la misma manera. Para obtener la **utilidad** de un **estado S**, sumamos los **productos** de la **utilidad** de cada **estado S prima** al que podemos llegar desde **S** con su respectiva **probabilidad**.

Aquí el valor de **utilidad V** de **S** no será la **recompensa instantánea**, sino la **utilidad horizonte infinito**.

Podemos tratar cada nodo del grafo como una lotería. Para el estado s tenemos que el valor esperado de utilidad es:



$$\sum_{s'} P(S^{t+1}=s' | S^t=s) V(s')$$

Recordemos que para una lotería podemos calcular su utilidad sumando los productos

La expresión para el valor **horizonte infinito de utilidad** nos lleva a una **ecuación** donde incorporamos tanto la **recompensa instantánea** como el valor esperado de **utilidad** para tiempos futuros. Aplicamos el **factor de descuento gamma** para las **recompensas** esperadas en tiempos futuros. Observamos que la expresión del **término** que corresponde con la **utilidad** de **estados** futuros puede expresarse como un **producto matricial**. El **producto** de la transpuesta en la **matriz de probabilidades de transición T** con el **vector de utilidades horizonte infinito V** de S. Aquí la **matriz T** es la **matriz de probabilidades de transición de una cadena de Markov**.

- La utilidad *horizonte infinito* considera la recompensa instantánea y el valor esperado de recompensa para tiempos futuros con su factor de descuento:

$$V(s) = R(s) + \gamma \sum_{s'} P(S^{t+1}=s' | S^t=s) V(s')$$

- Matricialmente:

$$V(s) = R(s) + \gamma T^T V(s)$$

- El cual podemos resolver:

$$V(s) = (I - \gamma T^T)^{-1} R(s)$$

Esta ecuación lineal puede resolverse invirtiendo una matriz.

Esta **ecuación lineal** puede resolverse **invirtiendo** una **matriz**. Ahora vamos a incorporar las **acciones** del **agente** en la **ecuación**.

Tenemos un **proceso estocástico** donde el **agente** no puede anticipar el efecto de sus acciones. Sin embargo, el **estado** siguiente **sí** va a depender de la **acción** que tome el **agente**, y también del **estado** en el que se encuentra. De otra forma, cualquier **política** sería igualmente buena.

Vamos a **considerar** que nuestro **agente** es **racional**, **esto es que trata de maximizar el valor esperado de utilidad horizonte infinito**. Dada esta consideración, el **proceso de edición de Markov** queda descrito por la **ecuación de Bellman**.

$$V(s) = R(s) + \gamma \max_a \sum_{s'} P(s' | s, a) V(s')$$

Observemos que aparece un **término no lineal máx**, el cual **modela** el **efecto** de la **acción racional** del **agente**, aquí representada con la letra **A**. Adicionalmente, se observa que la **probabilidad de transición** no solo está **condicionada** al **estado** actual, sino también a la **acción** del **agente**.

En la **teoría de decisiones**, si encadenamos **nodos de decisión** con loterías formando **árboles de decisión**, los **procesos de edición de Markov** pueden interpretarse de manera similar, pero dado que resultarían **árboles infinitos con probabilidades de transición estacionarias**, es mejor tratarlos como **grafos de decisión**.

Aquí comenzamos con los **estados**, los que representamos con **nodos de decisión**. Por ejemplo, un pasajero se encuentra en el **vagón comedor**. Nuestro **agente**, es decir el **tren inteligente**, puede **decidir** entre un **conjunto de acciones** para tratar de cambiar la **probabilidad** de que el pasajero **continúe o transite** a otro **vagón**.

Una **acción posible** es hacer un anuncio publicitario en el vagón. Esto no definirá la **acción** del pasajero, pero sí tendrá un efecto en la **probabilidad de transición de estado**.



La **transición** la representamos con un **nodo** de lotería. La lotería definirá el **estado** siguiente.



En este caso, podemos transitar a cualquiera de los vagones, quedarnos en el comedor, ir al dormitorio o al bar. Cada **arista** de la lotería tiene anotada la **probabilidad de transición**.

Para no saturar la figura, solo ilustraremos la **probabilidad de transitar al dormitorio**. Observamos que esta **probabilidad** está condicionada a encontrarnos en el vagón comedor y que el tren haga el anuncio uno.



También es posible que el tren no haga anuncio alguno. En este caso, tenemos otra lotería para **transitar de estado**. Así, para el **estado B**, tenemos **acciones** similares y las loterías respectivas, y para el **estado D**.



La pregunta relevante que hacer es ¿cuál es la **política óptima**? Es decir, qué **acción** debe tomar el **tren** en cada **vagón** tal que **maximice la utilidad horizonte infinito**. De la **ecuación de Bellman**, podemos ver que la **política óptima pi estrella de S** se obtiene con la **acción** que maximiza el valor esperado de **utilidad** para cada **estado**.

El problema de **diseño** del **agente** consiste en encontrar la **política óptima**. Para encontrar la **política óptima** tenemos que **resolver la ecuación de Bellman**.

La **ecuación de Bellman** es una **ecuación no lineal** donde aparece un **término no lineal** el **máximo** o el término **máx**. Para resolver la **ecuación de Bellman** no podemos invertir una matriz. Tenemos que **utilizar métodos numéricos**.

Deseamos resolver **$\Pi^*: S \rightarrow A$** :

$$\Pi^*(s) = \underset{a}{\operatorname{argm\acute{a}x}} \sum_{s'} P(s' | s, a) V(s')$$

Existen varios métodos numéricos para resolverla. Uno de ellos es el **algoritmo de iteración de valores**. En el **algoritmo de iteración de valores** comenzamos con una **asignación arbitraria** para **V** de **S** o **V(s)** e **iteramos** estos valores sobre la **ecuación de Bellman** hasta que **estos convergen** a los valores óptimos para encontrar **$\Pi^*(s)$** .

Una vez que tenemos esta **función V de S**, encontramos la **política óptima** muy fácilmente.


En el segundo algoritmo, en el **algoritmo de iteración de políticas**, no nos interesa encontrar el valor de la **función V de S**, sino que directamente tratamos de encontrar la **política óptima**.

En el **algoritmo de iteración de políticas** se itera la política. Comenzamos con una **política arbitraria**. Dada esta política arbitraria, se encuentra el valor de la **función V de S**, y con este valor de **V de S**, se selecciona la siguiente política. **Esto se repite hasta que la política no cambia**.

A continuación, presentamos un ejemplo del **algoritmo de iteración de políticas**. El **algoritmo de iteración de políticas** está basado en el hecho de que, dado una **política** conocida π , el **proceso de decisión de Markov** puede tratarse como una **cadena de Markov**.


Regresamos al ejemplo del tren. Ahora hemos anotado las **aristas** con **duplas de probabilidades**. Cada elemento de la **tupla** corresponde con una acción distinta. En el ejemplo, el **primer** elemento de la **tupla** corresponde con no anunciar. El **segundo** elemento corresponde con la opción anuncio.

La **política es una función**. Para cada **estado** nos dice **qué acción tomar**. Esta **función** puede representarse como una **lista de acciones**. La **posición** de la **acción** es la misma que la del **estado** correspondiente.




Podemos pensar en un **arreglo T** que tiene como entrada las **tuplas**. La **política** selecciona en cada **tupla** un elemento particular. En este caso, si la política para todo **estado** es no anunciar, entonces nuestra **matriz de probabilidades de transición** es la misma que en el ejemplo usado en el tema de **cadenas de Markov**.

Encontraremos la **utilidad horizonte infinito** para cada estado. Obsérvese que en la **ecuación de Bellman matricial**, la **matriz de transición de la cadena de Markov** aparece de forma transpuesta. Sustituimos, obtenemos los valores **horizonte infinito**.




Sustituimos, obtenemos los valores horizonte infinito.

En este paso, vamos a recalcular la **política pi 1 de S**. Para el **estado D**, encontraremos el **estado** que maximiza la utilidad. Así quedan las **sumatorias**.




Para el estado D, encontraremos el estado que maximiza la utilidad.

Sustituimos valores.




Sustituimos valores.

Tomaremos la **acción** que da el valor máximo. En este caso, hacer el anuncio resulta en una mayor **utilidad. Una utilidad de 103,81.**




Una utilidad de 103,81.

Pi 1 queda definida como hacer el anuncio si se está en el dormitorio o el comedor, pero no hacerlo si se está en el bar. Observamos que **pi 0** es diferente que **pi 1**, por lo que el **algoritmo** continuará iterando. Calculamos las **probabilidades de transición** para **pi 1**, y resolvemos el **sistema de ecuaciones** obteniendo los nuevos valores de **utilidad horizonte infinito V 1 de S**.



Recalculamos la **política óptima pi 2** observando que el **algoritmo convergió**. Y el **algoritmo** termina aquí.



Teoría de juegos

La **teoría de juegos** tiene aplicaciones en muchos dominios, economía, política, biología e inteligencia artificial. A diferencia de la **teoría de decisiones**, ahora estudiamos situaciones en las que hay que **tomar decisiones** en presencia de otros tomadores de decisiones.

Hay **tres componentes en un juego**, un **conjunto de actores o agentes**, que pueden ser animales, robots o programas de computadora. Por cada **agente** hay un **conjunto de acciones**. A cada **acción** hay asociada una **utilidad** o **ganancia**, que es el término usado en la **teoría de juegos**, y representa las preferencias de cada **agente**. Suponemos que cada **agente** es egoísta con respecto a su **ganancia**.

Es importante notar que el altruismo puede incorporarse al egoísmo. Es decir, si un **agente** desea el bien de la humanidad, por ejemplo, lograrlos deseos de ese **agente** va a consistir en lograr el bien de la humanidad.

Las **decisiones** de cada **agente** van a estar influidas por las **decisiones** de los **demás agentes**. Suponemos que todos los **agentes** conocen las **ganancias** de todos los **agentes**. Además, la manera de tratar de **predecir** el **comportamiento** de los demás se basa en asumir que todos los **agentes** son **racionales**, en el sentido de que eligen las **acciones** que **maximizan** su propia **ganancia**.

Vamos a ver el final de la historia del homicidio en el tren. En realidad, el homicidio no fue cometido por una sola persona, como creía nuestro detective, sino por dos. Para ilustrar la **teoría de juegos**, vamos ahora a suponer que el homicidio en nuestro tren fue cometido por dos personas **A** y **B**.

La policía captura a ambos sospechosos, pero no tiene evidencia suficiente para condenarlos. Es necesaria una confesión para condenarlos. Vamos a suponer que a cada sospechoso solo le importa su propio destino. Los sospechosos se encuentran en celdas separadas y no pueden comunicarse entre sí. La sentencia normal es de **diez años** de prisión. Sin embargo, si ninguno confiesa, el fiscal no puede más que acusarlos por un delito menor, como posesión de armas. En ese caso, los sospechosos son condenados a **un año** de prisión cada uno.

En cambio, si **A confiesa** que ambos cometieron el homicidio y **B permanece callado**, el fiscal, como premio a **A** por haber confesado, lo deja ir libre. Mientras que **B**, que no confesó, recibe toda la sentencia de **diez años**.


Simétricamente, si **B confiesa** y **A permanece callado**, **B** sale libre y **A** recibe toda la sentencia.

Finalmente, **si ambos confiesan**, digamos que el fiscal quiere premiar y castigar a la vez, en ese caso cada uno recibe la mitad de la sentencia, es decir, **cinco años**.

Lo ideal es que cada sospechoso coopere con el otro. Si ambos permanecen callados, reciben una sentencia pequeña de **un año**. Sin embargo, está la tentación de confesar para salir libre.

Vamos a representar las **cuatro posibilidades resultantes** de las **dos acciones** de cada sospechoso con una **matriz**. Si **A confiesa** y **B permanece en silencio**, **A** recibe cero años de prisión y **B** diez. Simétricamente, si **A permanece en silencio** y **B confiesa**, **A** recibe diez años de prisión y **B** cero. En

caso de que **ambos confiesen**, se reparten la sentencia. Si ninguno confiesa, el fiscal solo los acusa de portar armas y los condena a un año de prisión.



		B	
		callar	confesar
A	callar	1 / 1	0 / 10
	confesar	10 / 0	5 / 5

el fiscal solo los acusa de portar armas y los condena a un año de prisión.

¿Qué haría usted en el caso de estos sospechosos?

Vamos a ponernos en el lugar del sospechoso **A**. Si **B** elige permanecer callado, a nosotros nos va a convenir más confesar, pues salimos libres en lugar de recibir un año de prisión. Si **B** elige confesar, a nosotros nos va a convenir más confesar también, pues recibimos cinco años de prisión en lugar de diez. Independientemente de la acción elegida por **B** entonces, nos conviene más confesar.

Como suponemos que **B** es **racional** también, pensamos que **B** va a hacer un **razonamiento similar al nuestro** y que **B** también va a concluir que es mejor para él confesar que permanecer callado. Ambos agentes reciben entonces cinco años de prisión. Esta no es la situación ideal en la que cada **agente** recibiría solamente un año de condena.

Este **juego** es importante **porque modela multitud de situaciones de la vida real**. Explica, por ejemplo, por qué **dos compañías** que compiten entre sí se ven obligadas a bajar el precio de un producto, **reduciendo** su posible **ganancia** total. También explica por qué en ocasiones hay tratados entre países, por ejemplo, que no se firman o que sí se firman, pero no se cumplen. A la situación que tiene ambos círculos, se le llama el **equilibrio de Nash**.

Informalmente, un **equilibrio de Nash** es un **conjunto de acciones** para todos los **agentes**, tal que **ningún agente puede mejorar unilateralmente**. Es decir, es un **conjunto** de **mejores respuestas** a **mejores respuestas**. Es posible que haya más de un **equilibrio de Nash** o que no haya ninguno.

Vamos a ver otro ejemplo que puede verse como modelando a una pareja que planea una salida y prefieren ir juntos que separados, pero tienen diferentes preferencias de adónde ir. Las opciones son ballet y salsa. **A** prefiere ballet y **B** prefiere salsa. Ahora vamos a usar **ganancias** en lugar de pérdidas.

Supongamos que nos dan esa **matriz de ganancias**. Nos ponemos en el lugar de **A**. En caso de que **B** elija ballet, nos va a convenir más elegir ballet también, con una **ganancia** de dos en lugar de cero. En caso de que **B** elija salsa, nos va a convenir más elegir salsa también, con una **ganancia** de uno en lugar de cero. Simétricamente, podemos concluir que **B** va a hacer un **razonamiento equivalente**. **Ambas situaciones, ballet-ballet y salsa-salsa son equilibrios de Nash**. Ambas tienen dos círculos porque son mejores respuestas a mejores respuestas.

		B	
		ballet	salsa
A	ballet	(2, 1)	(0, 0)
	salsa	(0, 0)	(0, 2)

Simétricamente, podemos concluir que B va a hacer un razonamiento equivalente.

El área de **teoría de juegos** es enorme. Aquí solo ilustramos **estrategias puras**, o sea, **determinísticas**, pero también hay **estrategias mixtas con una componente probabilística**. Solo ilustramos **juegos** en forma normal o estratégica, en los que los **agentes** realizan una sola **acción** y simultáneamente. Pero también hay **juegos** extensivos con jugadas sucesivas. Solo vimos **juegos** con información **perfecta**. Los **juegos** estratégicos con información **imperfecta** se llaman **juegos bayesianos**.

$$\Sigma \rightarrow \epsilon \equiv \top \perp \Sigma \models \vdash \alpha \beta \in \ell \phi \subseteq \pi \exists \forall \models \models \neq \nexists \notin \in \Sigma \vee \top \perp \subset \gamma \vee \vdash \Pi$$